



UNIVERSIDAD NACIONAL DE ASUNCIÓN
FACULTAD POLITÉCNICA

INGENIERÍA EN INFORMÁTICA

Metodología para estimar pérdida de carbono a través de procesamiento de imágenes satelitales. Caso de uso Chaco Paraguayo

PROYECTO FINAL DE GRADO

Autor:

Santiago Smael Vera Aquino

Tutor:

Dr. Horacio Legal Ayala
MSc. José L. Vázquez Noguera

SAN LORENZO - PARAGUAY

DICIEMBRE - 2015

Dedicatoria

A mis hermanos, profesores, compañeros, amigos y en especial a mis padres por brindarme el apoyo incondicional de siempre.

Agradecimiento

Mi agradecimiento especial a mis tutores: MSc. José L. Vázquez Noguera y Dr. Horacio Legal por el tiempo y los conocimientos transmitidos. También a la Prof. Larissa Karina Rejalaga Noguera por su ayuda compartiendo conmigo sus conocimientos en el área forestal.

Resumen

El cambio climático es un problema de carácter mundial, que engloba distintos factores ligadas a las actividades humanas. Los bosques constituyen un medio principal de conservación de carbono, donde la deforestación y degradación contribuyen al aumento de los Gases de efecto invernadero (GEI). En los últimos 50 años la explotación Forestal y el cambio en el uso de la tierra, produjo la pérdida del 90 % de los bosques en la región Oriental del Paraguay, generados por degradaciones y deforestaciones en los suelos con destino a una progresiva desertificación que atenta contra la biodiversidad y los sumideros de carbono. A diferencia de la región oriental, en el occidente o Chaco Paraguayo aplicar mecanismos de control ambiental implica elevados costo, por lo que el empleo de metodologías que ayuden a determinar zonas de riesgos disminuirán en cierta proporción los gasto en monitoreos.

Esta investigación elabora una metodología práctica y dinámica para identificar focos de perdidas de carbono forestal empleando procesamiento digital de imágenes satelitales. Una vez identificado focos de riesgos, permitirá fortalecer planes y estrategias en los controles, con acciones más optimas y rigurosas en base a las estimaciones hechas.

La metodología propuesta cuenta con dos procedimientos generales, donde las bandas infrarroja cercana y roja de las imágenes satelitales para dos fechas, constituyen entradas en la generación de un mapa de perdida forestal (degradación y deforestación) con su correspondiente estimación de carbono perdidos en el área evaluada. Los procedimientos son los siguientes:

- Detección de cambio Forestal: mediante análisis estadísticos previos hechos a índices de vegetación y algoritmos basados en parámetros estadísticos para la detección del cambio, nos permiten obtener una máscara de perdida forestal.
- Estimación de Perdida de cambio forestal: se halló una correlación moderada ($r^2 = 0,509125$) entre el mapa global de carbono y el índice de vegetación, proporcionando una ecuación lineal que transforma en toneladas de carbono por hectárea dicho índice.

En el chaco paraguayo, específicamente parte del distrito de Filadelfia, departamento de Boquerón, fueron determinadas áreas en base a la presencia forestal (urbano, rural y húmedo), de manera a evaluar la metodología propuesta con distintos tipos de uso del suelo, sumándole un criterio de fiabilidad a la detección del cambio. Zonas rurales obtuvieron precisiones globales mayores al 85 % y coeficientes Kappa moderadas como también considerables, siendo las más satisfactorias en las pruebas experimentales. Estas pruebas fueron hechas a través de comparaciones entre resultados y estudios de perdida boscosa realizado al Paraguay, por The Global Land Cover Facility de University of Maryland Institute for Advanced Computer Studies.

La metodología propuesta nos brinda una herramienta valida en la generación de indicadores ambientales para monitoreos de áreas extensas. Estos indicadores representan alertas en áreas donde la deforestación y degradación forestal transforman los sumideros de carbono a zonas desérticas o productivas, contribuyendo así al cambio climático.

Palabras claves: Cambio climático, Gases de efecto invernadero, Sumideros de carbono, Procesamiento digital de imágenes satelitales, Sensores remotos, Precisión Global, Coeficiente kappa.

Abstract

Climate change is a global problem, which encompasses various factors linked to human activities. Forests are a major means of carbon conservation where deforestation and degradation contribute to increased greenhouse gases (GHG). In the last 50 years on Forest exploitation and the change in land use, it caused the loss of 90 % of the forests in eastern Paraguay, generated by deforestation and degradation in soils destined to progressive desertification threatens biodiversity and carbon sinks. Unlike the eastern region, western or Paraguayan Chaco apply environmental control mechanisms involves high cost, so that the use of methodologies that help determine risk areas will decrease to a certain proportion of expenditure monitoring.

This research develops a dynamic and practical methodology to identify sources of lost forest carbon using digital processing of satellite images. Once identified sources of risks, will strengthen plans and strategies in the controls, with more optimal and rigorous actions based on estimates made.

The proposed methodology has two general procedures, where the red and near infrared bands of satellite images for two dates are inputs in the generation of a map of forest loss (deforestation and degradation) with the corresponding estimate of carbon lost the area evaluated. The procedures are:

- Forest change detection: using pre-made statistical analysis of vegetation indices and statistical parameters based algorithms for change detection, allow us to obtain a mask of forest loss.
- Loss estimate of forest change: a moderate correlation was found ($r^2 = 0,509125$) between the global map of carbon and vegetation index, providing a linear equation that transforms into tons of carbon per hectare index said.

In the Paraguayan Chaco, specifically the district of Philadelphia, department Boqueron, were certain areas based on the presence forest (urban, rural and humid), so to evaluate the proposed methodology with different types of land use, adding reliability criteria change detection. Rural areas had higher overall accuracies of 85 % and moderate Kappa coefficients as also considerable, being the most successful in experimental tests. These tests were done through comparisons between results and studies of forest lost to Paraguay conducted by The Global Land Cover Facility of University of Maryland Institute for Advanced Computer Studies.

The proposed methodology provides us with a valid tool in the generation of environmental indicators for monitoring of large areas. These indicators represent alerts in areas where deforestation and forest degradation transform carbon sinks desert or productive areas, thereby contributing to climate change.

Keywords: Climate change, greenhouse gases, carbon sinks, digital satellite image processing, remote sensing, global precision, kappa coefficient.

Índice general

Agradecimiento	II
Resumen	III
Índice de figuras	X
Índice de símbolos	XII
Índice de tablas	XIV
Abreviaciones	XVII
1. Introducción	2
1.1. Justificación y Motivación	4
1.2. Antecedentes	5
1.3. Trabajos relacionados	5
1.4. Objetivos	12
1.4.1. Objetivos Generales	13
1.4.2. Objetivos Específicos	13
1.5. Organización de la Tesis	13
2. Cambio Climático	16
2.1. Ciclo de carbono	17
2.1.1. Secuestro de carbono	18
2.1.2. Pérdida de Carbono	18
2.1.3. Secuestro de carbono en Paraguay	18
2.1.4. Gran Chaco Americano	18
2.2. Biomasa	19
2.2.1. Biomasa Forestal	20
2.3. Medición de balances de carbono	20
2.4. Teledetección en el medio ambiente	21
2.5. Resumen	22
3. Procesamiento de imágenes satelitales	25
3.1. Sensores Remotos	25

3.1.1. El espectro electromagnético	26
3.1.2. Firmas espetrales	27
3.1.3. Resoluciones de un sensor	28
3.2. Imágenes satelitales	30
3.2.1. Histogramas	31
3.2.2. Combinación de bandas	32
3.3. Álgebra de mapas	33
3.4. Índices de vegetación	36
3.4.1. Índice de vegetación diferencial normalizada	36
3.4.1.1. Características del NDVI	37
3.5. Análisis Multitemporal	37
3.6. Correcciones a las imágenes satelitales	38
3.6.1. Corrección geométrica	38
3.6.1.1. Interpolación espacial	39
3.6.1.1.1. Transformación usando ecuaciones polinómicas .	39
3.6.1.1.2. Calidad de la interpolación espacial	40
3.6.1.2. Interpolación de los valores radiométricos	41
3.6.2. Corrección radiométrica	43
3.6.2.1. Pixeles o líneas perdidas	44
3.6.2.2. Bandeados	45
3.7. Proceso de detección de cambios	46
3.7.1. Normalización Radiométrica	47
3.7.2. Comparación multitemporal	49
3.7.3. Criterios de decisión	49
3.7.3.1. Discriminación de las zonas de cambio	50
3.7.4. Filtrado	51
3.8. Resumen	51
4. Materiales y Metodología	53
4.1. Materiales	53
4.1.1. Imágenes	54
4.1.1.1. Landsat	54
4.1.1.2. Campos Continuos de Vegetación (VCF)	55
4.1.1.3. Mapa global de carbono - Paraguay	56
4.1.1.4. Paraguay Forest Change Product	57
4.1.2. Aplicaciones	58
4.2. Metodología	59
4.2.1. Detección de cambio Forestal	60
4.2.1.1. Detección de cambio	60
4.2.1.1.1. Comparación Multitemporal	60
4.2.1.1.2. Umbral estadístico	60
4.2.1.1.3. Iteración	61
4.2.1.2. Discriminación Forestal	64
4.2.1.2.1. NDVI	64
4.2.1.2.2. Umbral de Vegetación	65
4.2.1.2.3. Intersección área boscosa	66
4.2.1.3. Máscara de Pérdida Forestal	66

4.2.2. Estimación de pérdida de carbono forestal	67
4.2.3. Esquema general de la metodología	69
4.3. Resumen	74
5. Pruebas experimentales	76
5.1. Caso de estudio	76
5.2. Métricas de evaluación	77
5.2.1. Porcentaje de precisión global	78
5.2.2. Coeficiente Kappa	78
5.3. Pruebas y resultados experimentales	79
5.3.1. Umbral de Vegetación	79
5.3.2. Estimación de pérdida de carbono forestal	82
5.3.3. Prueba experimental	83
5.3.4. Dificultades encontradas	90
5.3.5. Discusión de resultados	90
6. Conclusiones y trabajos futuros	93
6.1. Conclusiones	93
6.2. Trabajos futuros	94

Índice de figuras

2.1.	Calentamiento Global [cal].	16
2.2.	Ciclo de carbono [cic].	17
2.3.	Tipos de sensores.	21
2.4.	Teledetección [telb].	22
3.1.	Bandas capturadas por un satélite [telb].	27
3.2.	Firmas espectrales de diferentes coberturas.	28
3.3.	Resolución espacial [cha].	29
3.4.	Resoluciónpectral igual a 3 para el sensor SPOT y 7 en el sensor Landsat [MD05].	29
3.5.	Diferentes resoluciones radiométricas en imágenes satelitales	29
3.6.	Resolución temporal de 16 días [tel15].	30
3.7.	Valor digital en una imagen satelital de 4 bandas ($k = 4$) y resolución radiometrica $r = 8$	30
3.8.	Histograma de una imagen con niveles digitales de 0 a 255.	31
3.9.	Combinación de bandas espectrales a través de los canales RGB.	33
3.10.	Operadores locales condicional y lógico.	34
3.11.	Áreas situadas a una distancia inferior a los valores umbrales 25,50,75,100,125.	35
3.12.	Operador de área: Altitud media por áreas.	36
3.13.	Firmapectral de la vegetación [ndv].	37
3.14.	Localización de puntos comunes y puntos de referencia.	39
3.15.	Interpolación espacial con polinomios de primer y segundo orden.	40
3.16.	Error RMS de un punto de control (x, y) y su transformación (x', y')	41
3.17.	Interpolación Vecino más Cercano.	42
3.18.	Interpolación Bilineal.	43
3.19.	Convolución cúbica.	43
3.20.	Fallos del sensor en la captura de la imagen.	44
3.21.	Proceso de corrección del bandeo.	46
3.22.	Histogramas de la la banda i en los tiempos t, t_* junto con el de la imagen normalizada.	47
3.23.	Proceso de normalización radiometrica entre una imagen satelital en el tiempo t y t_*	48
4.1.	Ejemplo WRS-2 Path/Row	55
4.2.	Imagen VCF con diferentes tonalidades de color de acuerdo al porcentaje de vegetación.	56
4.3.	Mapa Global de Carbono - Paraguay	57
4.4.	Paraguay Forest Change Product	58

4.5. Diagrama de flujo. Metodología propuesta	59
4.6. Umbrales que binarizan los indices de cambios I_c	61
4.7. Diagrama de flujo. Detección de Cambio.	62
4.8. Mascaras de cambio, iteración de la normalización radiométrica.	64
4.9. Umbral utilizado y la media en el histograma de la imagen con NDVI.	65
4.10. Diagrama de flujo. Discriminación Forestal.	66
4.11. Diagrama de procedimientos para la obtención de la máscara de pérdida forestal.	67
4.12. Presentación del resultado. Mascara de pérdida Forestal y la cantidad de carbono perdido.	69
4.13. Bandas de imágenes satelitales utilizados como entrada.	71
4.14. Primera iteración en el proceso de detección de cambio.	71
4.15. Segunda iteración en el proceso de detección de cambio.	72
4.16. Última iteración en el proceso de detección de cambio.	73
4.17. Determinación de la máscara de vegetación MV.	73
4.18. Mascara de cambio forestal y cuantificación de pérdida de carbono forestal.	74
 5.1. Mascara VCF de 0-30 % sobre NDVI año 2000	80
5.2. Puntos aleatorios dentro de la mascara VCF.	80
5.3. Puntos aleatorios.	82
5.4. Regresión Lineal. $X = NDVI, Y = TonC/ha$	83
5.5. Áreas de los sectores empleados para los experimentos.	84
5.6. Área Urbana. Mapa de pérdida forestal y toneladas de carbono perdidos.	86
5.7. Área Rural. Mapa de pérdida forestal y toneladas de carbono perdidos .	86
5.8. Área Húmeda. Mapa de pérdida forestal y toneladas de carbono perdidos	87
5.9. Re-clasificación de la imagen PFCP. Perdida = 1, Otros=0	88
5.10. Coeficiente Kappa por cada Área y tolerancia.	89
5.11. GA por cada Área y tolerancia.	89

Índice de símbolos

r	Bits o Niveles radiométricos de la imagen satelital.
i	Banda de la imagen satelital.
(x, y)	Coordenadas espaciales.
f	Imagen satelital.
(x, y, i)	Coordenadas espaciales de la banda i en la imagen satelital.
k	Número de bandas que posee una imagen satelital.
col	Número de columnas de la imagen f .
$f(x, y, i)$	Nivel digital en la posición (x, y) de la banda i de la imagen satelital f .
fil	Número de filas de la imagen f .
ND	Nivel digital de una imagen satelital.
$H(ND)$	Función discreta que determina la cantidad de apariciones de ND , en la imagen satelital.
n_{ND}	Número de pixeles en la imagen satelital teniendo el nivel digital ND .
ρ	Operador local utilizada para álgebra de mapa.
$ndvi_f$	Imagen del índice de vegetación diferencial normalizada (NDVI) de f .
$ndvi_f(x, y)$	NDVI de la coordenada (x, y) de la imagen f .
R	Posición de la banda roja en la imagen satelital.
IRc	Posición de la banda infrarroja cercana en la imagen satelital.
$T[f]$	Operador que corrige la imagen satelital f .
l	Grado del polinomio de ajuste.

(x', y')	Coordenadas de la imagen transformada.
RMS_i	Error cuadrático de la banda i .
η	Número de puntos de control.
μ	Valor de la media.
σ	Desviación típica.
i_*	Banda de la imagen satelital.
σ_i	Desviación típica de la banda i de una imagen satelital.
σ_{i*}	Desviación típica de la banda i_* de una imagen satelital.
f_t	Imagen satelital en el tiempo t de una secuencia multitemporal.
$f'(x, y, i)$	Nivel digital en la posición (x, y) , en la banda i , de la imagen satelital corregida f' .
I_{dif}	Indice de cambio por diferencia de imágenes.
I_{ratio}	Indice de cambio por el método de ratio.
I_c	Indice de cambio entre dos imágenes.
B	Imagen binaria en el proceso de detección de cambio.
$B(I_c)$	Nivel digital para el I_c .
U	Umbral que binariza una imagen en base a un I_c .
n	Coeficiente de fiabilidad de los datos.
$Z_{t,i}$	Variable tipificada.
μ_{I_c}	Media de la imagen de Índices de cambio.
σ_{I_c}	Desviación típica de la imagen de Índices de cambio.
$f_t^{Norm}(x, y, i)$	Imagen normalizada, de la banda i .
ϵ	Error de cambio.
σ_c	Desviación determinada como constante para la umbralización de la cobertura vegetal.
(m, h)	Coeficiente en la ecuación de estimación de carbono.
r^2	Coeficiente de determinación para una regresión.

$C(x, y)$ Toneladas de carbono por hectárea en las coordenadas (x, y) .

$PC(x, y)$ Toneladas de carbono por hectárea perdidos en las coordenadas (x, y) .

VT Puntos de verdad terreno.

T Puntos catalogados correctamente.

F Puntos catalogados incorrectamente.

TP Pixeles que se catalogaron como perdida correctamente.

FP Pixeles que se catalogaron como perdida incorrectamente.

P Total de pixeles catalogados como perdida.

N Total de pixeles catalogados como no perdida.

TN Pixeles que se catalogaron como no perdida correctamente.

FN Pixeles que se catalogaron como no perdida incorrectamente.

P' Total de pixeles con perdida.

N' Total de pixeles con no perdida.

Índice de tablas

1.1.	Resumen de trabajos relacionados.	12
2.1.	Problemática que afrontan los países del gran chaco americano [Dua12]. .	19
4.1.	Resoluciones de los satélites Landsat.	54
4.2.	Representación del valor digital en la imagen PFCP.	58
4.3.	Rangos del coeficiente de determinación.	67
5.1.	Matriz de Confusión	77
5.2.	Valoración del coeficiente kappa.	79
5.3.	Media y desviación del muestreo realizado.	81
5.4.	Polígono de las áreas. Sistema de coordenadas UTM Zona 20 K.	85
5.5.	Path/row de las imágenes utilizadas en el experimento.	85
5.6.	Coeficiente Kappa y precisión Global obtenidos.	88

Lista de Algoritmos

1.	Función que calcula los parámetros estadísticos.	63
2.	Metodología para estimar pérdida de carbono	70

Abreviaciones

GEI	<i>Gases de Efecto Invernadero.</i>
CO2	<i>Dióxido de carbono.</i>
C	<i>Carbono.</i>
SIG	<i>Sistemas de Información Geográficas.</i>
REDD+	<i>Reducción de GEI por la Deforestación y Degrado de bosques.</i>
RMSE	<i>Error cuadrático medio.</i>
ParLu	<i>Paraguay Land Use.</i>
WWF	<i>World Wildlife Fund.</i>
ENPAB	<i>Estrategia nacional y plan de acción para la conservación de la Biodiversidad.</i>
VD	<i>Valor Digital.</i>
FMAM	<i>Fondo para el Medio Ambiente Mundial.</i>
PDD	<i>Programa de Pequeñas Donaciones.</i>
LiDAR	<i>Detección área de luz y medidas de rango.</i>
NDVI	<i>Índice de vegetación diferencial normalizada.</i>
UTM	<i>Universal Transverse Mercator.</i>
RMS	<i>Root Mean Squared Error.</i>
NASA	<i>National Aeronautics and Space Administration.</i>
MSS	<i>Multi-spectral Scanner.</i>
TM	<i>Thematic Mapper.</i>
ETM+	<i>Enhanced Thematic Mapper Plus.</i>
OLI	<i>Operational Land Imager.</i>
TIRS	<i>Thermal Infrared Sensor.</i>
VCF	<i>Vegetation Continuous Fields.</i>
MODIS	<i>MOderate-resolution Imaging Spectroradiometer.</i>
PFCP	<i>Paraguay Forest Change Product.</i>

USGS	<i>United States Geological Survey.</i>
L1T	<i>Level 1 Terrain Corrected.</i>
GPL	<i>General Public License.</i>
GA	<i>Global Acurrancy.</i>
WRS-2	<i>Landsat Worldwide Reference System-2.</i>
PFCP	<i>Forest Change Produc.</i>
Km	<i>Kilómetros.</i>
Has	<i>Hectáreas.</i>
GCP	<i>Global Control Points .</i>

Capítulo 1

Introducción

La captura de carbono es un servicio ambiental proporcionado por los bosques para mitigar las emisiones de dióxido de carbono (CO₂) a la atmósfera [Oje13]. La captura de carbono es determinante para disminuir el calentamiento global y estabilizar el cambio climático producidos por el incremento en la atmósfera de los llamados Gases de Efecto Invernadero (GEI) [MD]. El CO₂ es el gas mas abundante, contribuyendo con un 76 % al GEI [ÁJB⁺01], debido principalmente al cambio de paisajes de bosques tropicales maduros a paisajes agrícolas.

Los bosques tropicales en condiciones naturales contienen más carbono aéreo por unidad de superficie que cualquier otro tipo de cobertura terrestre [GBNF07]. Por esto, cuando los bosques se convierten a otros usos del suelo, ocurre una gran liberación neta de carbono a la atmósfera. El cambio en el uso del suelo es responsable del 15-20 % de las emisiones totales de gases de efecto invernadero [Oje13].

Las transformaciones química de compuestos, que contienen carbono en los intercambios entre biosfera, atmósfera, hidrosfera y litosfera son conocidas como ciclo de carbono [Wik15]. La fotosíntesis de las plantas constituye un proceso fundamental en el ciclo, ya que permite separar el CO₂ en oxígeno que consumimos y carbono (C) en materia orgánica, actuando en forma de almacenes de C como biomasa en función a la composición florística, la edad y la densidad de cada estrato por comunidad vegetal por períodos prolongados [AMVMEB⁺03].

El término biomasa se refiere a toda la materia orgánica que proviene de árboles, plantas y desechos de animales que pueden ser convertidos en energía. La biomasa forestal se define como la cantidad total de materia orgánica aérea presente en los árboles incluyendo hojas, ramas, tronco principal y corteza [GS03].

La teledetección o percepción remota sin estar en un contacto físico directo permite el uso de informaciones provenientes de sensores instalados en plataformas espaciales, que complementados con sistemas de información geográficas (SIG) permiten análisis mas continuos y dinámico. Estos sensores remotos captan la energía reflejada o radiada por la superficie, ya sea emitida por el sol (sensores pasivos) o por el mismo sensor (sensores activos), para ser transformadas a valores digitales (VD) como imágenes satelitales, de manera secuencial para cada espacio de la tierra, a intervalos regulares de tiempo.

Las coberturas vegetales, a través de la imágenes proveídas por los sensores remotos, es posible calcular índices que varían dentro de márgenes, indicando el vigor de la vegetación o la densidad de la biomasa forestal. Estos índices junto con la comparación multitemporal hace posible identificar la evolución de coberturas vegetales en periodos de tiempos obteniendo resultados cualitativos y/o cuantitativos en espacio y tiempo [MG13].

En la actualidad existen diferentes métodos para la detección de cambios de vegetación. Los métodos requieren una supervisión, un trabajo de campo y la utilización de complejos sistemas de información geográfica. Estos sistemas de información geográfica son comúnmente software de pago, elevando de esta manera el costo de dichos estudios.

La falta de información nos lleva a varios cuestionamientos referente a como estamos manejando nuestro medio ambiente y que efectos acarreara esos usos. El empleo de la teledetección y las imágenes satelitales multitemporales permiten realizar un análisis a lo largo del tiempo de los cambios que el ambiente está experimentando, mas aun en zonas como el Chaco Paraguayo, donde la información ambiental es escaso por los altos costos y dificultades en el acceso al realizar controles en el terreno.

Se propone diseñar e implementar una metodología automática que permita estimar la

pérdida de carbono a través de la biomasa, empleando procesamiento digital de imágenes satelitales, disponibles de forma libre, dinámicos y no complejos.

1.1. Justificación y Motivación

REDD+ es una iniciativa que tiene como objetivo reducir la pérdida de bosques, teniendo como actividades principales [Oje13]:

- Evitar pérdidas como emisiones de gases de efecto invernadero (conservación, no deforestación, no degradación).
- Mantener el depósito o stock de carbono (conservación, gestión sostenible).
- Incrementar el depósito por su efecto de retención o sumidero de carbono (conservación, restauración, gestión sostenible).

El Paraguay se ha embarcado en el proceso de preparación para reducir la deforestación y degradación forestal, a fin de disminuir las emisiones de CO₂, conservar los bosques y su biodiversidad. Este proceso deriva la necesidad de elaborar una estrategia nacional, con políticas socio ambientales y económicas viables.

Para medir los beneficios de carbono de un proyecto REDD+ es necesario calcular la cantidad de carbono almacenado en el bosque en cuestión y luego predecir la cantidad de carbono que se podría conservar si se detiene o reduce la deforestación y la degradación forestal [Nel].

Las grandes extensiones de las áreas de estudio, la dificultad de acceder a las mismas, el alto costo del establecimiento de las parcelas de inventario y su limitada utilidad hacen que la mayoría de las investigaciones para estimar y mapear la biomasa en bosques se centren en las técnicas de Sensores Remotos.

La necesidad de crear metodologías que ayuden al monitoreo de forma dinámica y barata, lleva al desarrollo de herramientas libres que permitan estimar focos de alerta para la toma de acciones y controles más rigurosos a tiempo.

1.2. Antecedentes

Paraguay es un país que basa su economía en la agricultura y la ganadería extensiva, actividades que han afectado al recurso forestal, dando como resultado extensas áreas deforestadas y degradadas [Par].

En el informe realizado por la ENPAB [BdFM03] se menciona que existe una fuerte presión política y social, proveniente de diversos grupos que buscan transformar las tierras del Chaco paraguayo en unidades económicas de producción, cuyo enfoque gira en torno al crecimiento económico antes que al desarrollo sostenible. En muchas zonas del chaco paraguayo, el modelo de desarrollo y uso de la tierra ha producido grandes extensiones de tierras altamente degradadas, arenales, desertificación y salinización.

A pesar que existen leyes de protección para evitar la deforestación y valorar los bosques, los mismos necesitan apoyo para su monitoreo y aplicación efectiva, debido a que los costos en tiempo y recursos son elevados.

Con el objetivo de implementar políticas de mitigación del cambio climático relativas a reducir las emisiones provenientes de la degradación y la deforestación (REDD+), los países en desarrollo deben contar con estimaciones robustas sólidas en cuanto a las reservas de carbono forestal [Par].

1.3. Trabajos relacionados

El proyecto del Mapa global de carbono fue desarrollado por el Jet Propulsion Laboratory, California Institute of Technology en el año 2011 [SHB⁺¹¹], abarcando más de 2.5 millones en hectáreas de bosques, para tres continentes, trazando el stock total de carbono en la biomasa viva (por debajo y por encima). La incertidumbre media en las estimaciones realizadas para todos los continentes fue de $\pm 30\%$.

En el marco denominado *Desarrollo del estudio de linea de base para el sitio piloto Bosque atlántico de Alto Paraná. (BAAPA)* [Par], fue confeccionado un mapa de carbono en base al análisis de regresión entre el índice de vegetación diferencial normalizada

(NDVI) y toneladas de carbono por hectárea. El coeficiente de determinación hallado fue $r^2 = 0,64$.

Vanessa Almando Duré [Dur14a] estima el carbono almacenado en el Parque Nacional Defensores del chaco según formación vegetal a través de imágenes satelitales . La metodología utilizada corresponde a un análisis de regresión entre el NDVI y toneladas de carbono por hectárea. La investigación evaluó tres tipos de comunidades vegetales obteniendo coeficientes de determinación similares a $r_1^2 = 0,8$, $r_2^2 = 0,7$, $r_3^2 = 0,8$.

Gustavo Miguel Huespe Duarte [Dua12] detecta el cambios en la cobertura vegetal mediante índices de vegetación (NDVI), dentro y fuera de la reserva de la biosfera del Chaco en el periodo 1985-2011.

Tyukavina et al. [TBH⁺15] estima la pérdida de carbono sobre el suelo en los bosques tropicales naturales y gestionados para los años 2000-2012. La estimación fue hecha en todos los continentes, donde la incertidumbre en los resultados de América Latina fueron de $\pm 8\%$.

Maxime Réjou-Méchain et al. [RMTB⁺15] utiliza un modelo repetido para inferir variaciones espaciales y temporales de un bosque neotropical con alta biomasa mediante la adquisición del small-footprint LiDAR. El modelo presenta un error cuadrático medio (RMS) del 14% para resoluciones de 1 hectárea y de 23% para una resolución de 0,25 hectáreas en las variaciones de biomasa.

Jean Pierre Ometto et al. [OAA⁺15] realiza un mapa densidad de biomasa forestal en el Amazonas. El método estima las variaciones espaciales de la biomasa utilizando el análisis de imágenes satelitales. El modelo presenta valores de incertidumbres en su estimación para el periodo 1990-1999 del $\pm 15\%$ y 2000-2009 del $\pm 14\%$.

Michael W. Palace et al. [PSD⁺15] realiza estimaciones de la estructura de un bosque tropical mediante mediciones de campo, un modelo sintético y discreto a partir de datos retornados por un sensor lidar. En estimaciones de campo realizadas para alturas dosel se obtuvo un $r^2 = 0,17$. El modelo sintético desarrollado estima muchas propiedades estructurales de los bosque, tales como, medida de diámetro del tronco con $r^2 = 0,51$

y densidad de árboles con $r^2 = 0,43$.

Nancy L. Harris et al. [HBH⁺12] desarrolla un mapa de referencia para las emisiones de carbono producidas por deforestaciones en bosques tropicales. El mapa presenta un intervalo de predicción de 0,57 a 1,22 petagramos de carbono por año (Pg C year^{-1}).

Un estudio realizado por University of Maryland Institute for Advanced Computer Studies denominado Forest Cover Change in Paraguay, nos muestra el cambio de vegetación estimado en todo el país entre los años 1990 y 2000 [HKS⁺09]. Los resultados para todas las escenas (Fotografías áreas y satelitales) obtuvieron precisiones globales mayor al 90 % y errores por comisión y omisión menores al 10 %.

Xiao-Peng Song et al. [SHS⁺14] realiza una detección anual de cobertura vegetal perdido, utilizando imágenes satelitales multitemporales que contienen porcentaje de cobertura vegetal. El método empleado encuentra una relación entre imágenes satelitales de Vegetation Continuous Fields (VCF) y muestras de datos correspondientes a vegetación en imágenes satelitales Landsat. Los coeficientes de determinación van de 0,7 a 0,9 en los porcentajes de vegetación.

Clovis Grinand et al. [GRG⁺13] estima la deforestación en los bosques húmedos y secos tropicales de Madagascar desde 2000 hasta 2010. La estimación es hecha utilizando imágenes satelitales Landsat multitemporales y la clasificación de bosques al azar. Los resultados obtiene un error de comisión del 85 % para coberturas estables y 61 % para coberturas con cambios.

Matthew L. Clark et al. [CAGR10] propone un enfoque escalable para cartografiar anualmente la cubierta terrestre a 250 m utilizando datos MODIS de series de tiempo utilizando como caso de estudio la ecorregión chaco seco de América del Sur. El enfoque presenta una precisión global del 79 % en la clasificación de tipos de coberturas.

Dolors Armenteras et al. [ACRR13] calcula determinantes nacionales y regionales de la deforestación tropical en Colombia. El estudio presenta los coeficientes de determinación para cada región del país y nacionalmente en base a la deforestación y los diferentes tipos de usos del suelo.

Gu et. al [GW15] realiza un estudio para reducir la escala de 250 m que poseen las imágenes satelitales MODIS NDVI, sobre imágenes satelitales multitemporales Landsat utilizando enfoques de minerías de datos. La temporada de evaluación fue la etapa de crecimiento vegetal. El coeficiente de determinación hallado a partir del MODIS NDVI y el calculado a través de imágenes landsat fue de $r^2 = 0,97$.

En la siguiente tabla 1.1 se presenta un resumen de los trabajos relacionados.

Año	Autores	Trabajo	Evaluaciones
2009	Huang et al.	Assessment of Paraguay's forest cover change using Landsat observations	Presiciones globales mayores al 90 % y errores por comisión menores al 10 %
2010	Matthew L. Clark et al.	A scalable approach to mapping annual land cover at 250 m using MODIS time series data: A case study in the Dry Chaco ecoregion of South America	Presición global del 79 %
2011	Saatchi et al.	Benchmark map of forest carbon stocks in tropical regions across three continents	Incertidumbre media en las estimaciones del 30 %
			Continua...

2012	Gustavo Miguel Huespe Duarte	Detección de cambios de la cobertura vegetal mediante índices de vegetación (NDVI), dentro y fuera de la Reserva de la biosfera del Chaco en el periodo 1985-2011	Presenta conclusiones acerca del cambio detectado en diferentes regiones del caso de estudio.
2012	Nancy L. Harris et al.	Baseline map of carbon emissions from deforestation in tropical regions	Intervalo de predicción entre 0,57 a 1,22 (Pg C year ⁻¹)
2013	ParLu, WWF Paraguay y la Facultad de Ciencias Agrarias	Desarrollo del estudio de linea de base para el sitio piloto Bosque atlántico de Alto Paraná. (BAA-PA)	Coeficiente de determinación entre el NDVI y carbono r ² =0.64
Continua...			

2013	Clovis Grinand et al.	Estimating deforestation in tropical humid and dry forests in Madagascar from 2000 to 2010 using multi-date Landsat satellite images and the random forests classifier	Error de comisión del 85 % para coberturas estables y 61 % para coberturas con cambios.
2013	Dolors Armenteras et al.	National and regional determinants of tropical deforestation in Colombia	Coeficientes de determinaciones por regiones del país.
2014	Xiao-Peng Song et al.	Annual detection of forest cover loss using time series satellite measurements of percent tree cover	Coeficientes de determinación entre 0,7 – 0,9
Continua...			

2014	Vanessa Almando Duré	Estimación de carbono almacenado en el Parque Nacional Defensores del Chaco según formación vegetal mediante imágenes satelitales, año 2014	Coeficientes de determinación $r_1^2 = 0,8$, $r_2^2 = 0,7$, $r_3^2 = 0,8$
2015	Tyukavina et al.	Aboveground carbon loss in natural and managed tropical forests from 2000 to 2012	Incertidumbre en los valores estimados de $\pm 8\%$
2015	Réjou-Méchain et al.	Using repeated small-footprint LiDAR acquisitions to infer spatial and temporal variations of a high-biomass Neotropical forest	RMS 14% y 23% en las pruebas.
2015	Jean Pierre Ometto et al.	Amazon forest biomass density maps: tackling the uncertainty in carbon emission estimates	Incertidumbre en los valores estimados de $\pm 15\%$ y $\pm 14\%$
			Continua...

2015	Michael W. Palace et al.	Estimating forest structure in a tropical forest using field measurements, a synthetic model and discrete return lidar data	Coeficientes de determinación $r^2 = 0,17$, $r^2 = 0,51$, $r^2 = 0,43$
2015	Gu et al.	Downscaling 250-m MODIS Growing Season NDVI Based on Multiple-Date Landsat Images and Data Mining Approaches	Coeficiente de determinación $r^2 = 0,97$

TABLA 1.1: Resumen de trabajos relacionados.

En esta sección pudimos observar que existen diferentes trabajos relacionados a la estimación de carbono y detección de cambio forestal, tanto a nivel nacional e internacional. Este trabajo pretende diseñar una metodología, interceptando los dos tópicos mencionados, que estime pérdidas de carbono forestal de manera dinámica. Aquellos procedimientos que agilizan la estimaciones ahorrando visitas al terreno y supervisiones humanas en los mismos son los que determinan el dinamismo.

1.4. Objetivos

Atendiendo a la necesidad de metodologías alternativas para el monitoreo de pérdida de carbono en el campo ambiental, los objetivos delineados son los siguientes.

1.4.1. Objetivos Generales

- Desarrollar una metodología automática de análisis de imágenes satelitales multitemporales para la generación de indicadores respecto a la pérdida del contenido de carbono en zonas del Chaco Paraguayo.
- Diseñar un método de detección de cambio forestal automatizada entre secuencias multitemporales de imágenes satelitales.

1.4.2. Objetivos Específicos

Para el logro de los objetivos generales los siguientes objetivos específicos son propuestos:

- Establecer normalizaciones de imágenes para la comparación multitemporal.
- Determinar una constante para la clasificación de vegetación en imágenes satelitales.
- Determinar la relación entre el NDVI y el carbono a través de muestreos.
- Evaluar la detección de cambio forestal con el estado del arte.

1.5. Organización de la Tesis

La distribución de capítulos del presente trabajo final de grado se encuentra organizado de la siguiente forma:

- En el capítulo 2 se describen los conceptos generales relacionados al cambio climático y pérdida de carbono.
- En el capítulo 3 se pretende dar un marco teórico acerca del procesamiento digital de imágenes satelitales.
- En el capítulo 4 se detalla los algoritmos y procedimientos empleados en la metodología de estimación de pérdida de carbono.
- En el capítulo 5 se presenta las métricas para medir la calidad de los resultados. También se evaluá los resultados en base a las métricas previstas.

- En el capítulo 6 se presentan las conclusiones finales tras los experimentos y análisis de resultados del proyecto, concluyendo con propuestas de trabajos futuros para dar continuidad al trabajo final de grado.

Capítulo 2

Cambio Climático

El cambio climático es definido como cualquier variación del clima a lo largo del tiempo, ya sea por variabilidad natural o como resultado de las actividades humanas que altera la composición de la atmósfera y que se suma a la variabilidad climática natural observada en periodos de tiempos comparables [Rob02].

En la Figura 2.1 podemos observar como el planeta tierra esta cubierta por una capa de gases que deja penetrar energía solar que calienta la superficie terrestre. Algunos de los gases en la atmósfera, llamados gases de efecto invernadero (GEI), impiden el escape de este calor hacia el espacio . El escape de calor mantiene a la tierra a una temperatura promedio arriba del punto de congelación del agua y permite la vida. A pesar de esto, las actividades humanas están produciendo un exceso de gases que están potencialmente calentando el clima de la tierra [Dur14c].




FIGURA 2.1: Calentamiento Global [cal].

2.1. Ciclo de carbono

Las plantas absorben el dióxido de carbono existente en el aire o el agua, acumulándolos en los tejidos vegetales en forma de materia orgánica, mediante la fotosíntesis [nat15]. Posteriormente, los animales herbívoros se alimentan de estos vegetales para transferir esa energía a los demás niveles (carnívoros que se alimentan de los herbívoros). La energía transferida sigue varios caminos: por un lado es devuelto a la atmósfera como dióxido de carbono mediante la respiración; por otro lado se deriva hacia el medio acuático, donde puede quedar como sedimentos orgánicos, o combinarse con las aguas para producir carbonatos y bicarbonatos (suponen el 71 % de los recursos de carbono de la Tierra). La acumulación de carbono en zonas húmedas genera turba (carbón ligero y esponjoso), resultado de una descomposición incompleta, lo que da lugar a la formación de depósitos de combustibles fósiles como petróleo, carbón y gas natural.

El ciclo del carbono queda completado gracias a los organismos descomponedores, los cuales llevan a cabo el proceso de mineralizar y descomponer los restos orgánicos, cadáveres, excrementos, entre otros. Además de la actividad que llevan a cabo el reino vegetal y animal en el ciclo, también liberan carbono la putrefacción y la combustión [nat15]. La Figura 2.2 nos presenta el ciclo completo del carbono.




FIGURA 2.2: Ciclo de carbono [cic].

2.1.1. Secuestro de carbono

El CO₂ y otros gases invernaderos actúan atrapando la energía calórica (radiación solar de onda corta) reflejada de la superficie de la tierra y las nubes [Esp]. Este calor retenido puede conducir al calentamiento global en el planeta. Los niveles del dióxido de carbono atmosférico pueden reducirse en la misma medida que los niveles de carbono orgánico del suelo aumentan a través del secuestro de carbono. Si el carbono orgánico del suelo no es alterado, puede permanecer en el suelo por muchos años como materia orgánica estable. Este carbono es entonces secuestrado o removido de la atmósfera para ser reciclado. De esta forma se pueden reducir los niveles de CO₂, disminuyendo las probabilidades de calentamiento global [Cas03].

2.1.2. Pérdida de Carbono

Pérdida de carbono se refiere a aquella porción de carbono que no pudo ser almacenada o capturada en el intercambio normal que ocurre entre la superficie terrestre y la atmósfera en el ciclo de carbono [MD], contribuyendo al calentamiento global mediante la emisión de dióxido de carbono que compone el grupo de gases de efectos invernaderos.

2.1.3. Secuestro de carbono en Paraguay

El Fondo para el Medio Ambiente Mundial (FMAM) y el Programa de Pequeñas Donaciones (PDD), en nuestro país, nos dice que el uso de hidrocarburos para generar energía eléctrica, el uso de biomasa como fuente de energía, las emisiones industriales, la deforestación, los incendios forestal, la actividad pecuaria, el manejo y disposición de residuos y la actividad del transporte son los que presentan mayores emisiones de carbono [Piz10], en consecuencia contribuyen al cambio climático.

2.1.4. Gran Chaco Americano

En el territorio del Gran Chaco Americano, se detecta una tendencia de importante aumento de las tasas de deforestación diaria por encima de las 1.400 hectáreas, siendo el promedio del período 15 de junio al 10 de julio de 2.011, de 1.042 hectáreas por día, y del período 10 de julio al 13 de agosto de 2.011 de 1.408 hectáreas por día en toda la

región, dando un total de 47.856 hectáreas de áreas boscosas que registraron cambio a uso agropecuario, en 34 días. Entre los países que componen el Gran Chaco Americano, Paraguay registró el mayor porcentaje de la deforestación (86 %), seguido por Argentina (13 %) y Bolivia (1 %). En Brasil, no se detectaron caso de deforestación para la región. En el caso específico de Paraguay, la tasa de deforestación diaria ha aumentado, pasando de 998 hectáreas por día a 1.210 hectáreas por día [fao03], perdiéndose por consiguiente en gran medida sumideros de carbono, lo cual va aportando al desequilibrio del ciclo. En la Tabla 2.1 podemos observar los principales problemas ambientales que afronta el Gran Chaco Americano, en cada país que lo compone.

TABLA 2.1: Problemática que afrontan los países del gran chaco americano [Dua12].

Argentina	Bolivia	Paraguay
Deforestación de los bosques nativos.	Deforestación de los bosques nativos.	Deforestación de los bosques nativos.
Excesiva dependencia de la producción ganadera y explotación forestal.	Sobrepastoreo.	Sobrepastoreo.
Sobrepastoreo.	Incendios de bosques y pastizales.	Incendios de bosques y pastizales.
Incendios de bosques y pastizales.	Pérdida de biodiversidad.	Manejo no sustentable de los recursos hídricos.
Perdida de labiodiversidad.	Cambio climático.	Pérdida de biodiversidad.
Cambio climático.		Cambio climático.

2.2. Biomasa

La biomasa es aquel material orgánico biodegradable y no fosilizado originado de plantas, animales y microorganismos; incluye productos, subproductos, residuos y desechos de la agricultura, forestería e industrias afines, así como las fracciones orgánicas y no fosilizadas de los desechos industriales y municipales. La biomasa también incluye los gases y líquidos recuperados de la descomposición de materiales orgánicos biodegradables y no fosilizados [SH08]. La biomasa es considerada como la masa total de organismos vivos en una zona o volumen determinado (a menudo también se incluyen los restos de plan que han muerto recientemente). La cantidad de biomasa se expresa mediante su peso en seco o su contenido de energía de carbono o de nitrógeno [GMKM⁺⁸⁷].

2.2.1. Biomasa Forestal

La biomasa forestal se define como el peso (o estimación equivalente) de materia orgánica que se encuentra en un determinado ecosistema forestal por encima y por debajo del suelo [SGG00], normalmente es cuantificada en toneladas por hectárea de peso verde o seco. La biomasa forestal es frecuentemente separada en componentes, donde los más típicos corresponden a la masa del fuste, ramas, hojas, corteza, raíces, hojarasca y madera muerta.

En términos de pérdida y secuestro, representa la cantidad potencial de carbono que puede ser liberada a la atmósfera, debida a la deforestación, o la conservada en superficies terrestres cuando los bosques son correctamente gestionados [LB05].

2.3. Medición de balances de carbono

La dinámica del balance de carbono en un ecosistema forestal es muy compleja de medir, ya que es necesario determinar la captura de carbono por crecimiento de biomasa en los árboles y otros componentes en la vegetación como las pérdidas ocasionadas por disturbios, sean naturales o por actividades humanas; descomposición de madera muerta; y la transferencia entre los compartimentos vivos, muertos y el suelo [A⁺08].

Existen metodologías que permiten medir y monitorear cambios en reservorios promedios de carbono por unidad de área. A continuación se citan algunos de ellos:

- **Inventarios forestales:** se establecen relaciones alométricas con mediciones de terreno en función al diámetro o volumen de árboles con las reservas de carbono forestal. La desventaja que presenta es su lentitud al realizar en áreas grandes y costo elevado que presenta [AKB⁺05]. Definiendo alometría como los cambios de dimensión relativa de las partes corporales correlacionados con los cambios en el tamaño total.
- **Sensores remotos:** existen diferentes tipos de sensores que permiten monitorear cambios en reservorios de carbono vegetal con mayor dinamismo y a gran escala [Tsu12]. Podemos citar:

1. **Sensores remotos ópticos (pasivos):** capturan luz solar o artificial reflejada desde el objeto, detectando la intensidad de luz visible e infrarroja en una o mas longitudes de ondas.
2. **Sensores remotos activos:** este sensor se encuentra montado en un satélite, el cual emite pulsos de microondas oblicuamente detectando y registrando la intensidad, fase y tiempo de los impulsos reflejados desde la superficie terrestre.
3. **Sensores remotos láser como LiDAR (detección área de luz y medidas de rango):** mide la distancia entre el sensor y el objeto usando el tiempo que tarda el pulso en viajar y la intensidad del pulso reflejado del objeto.

La Figura 2.3 nos muestra como la información es capturada, por medio de los 3 tipos de sensores descriptos.

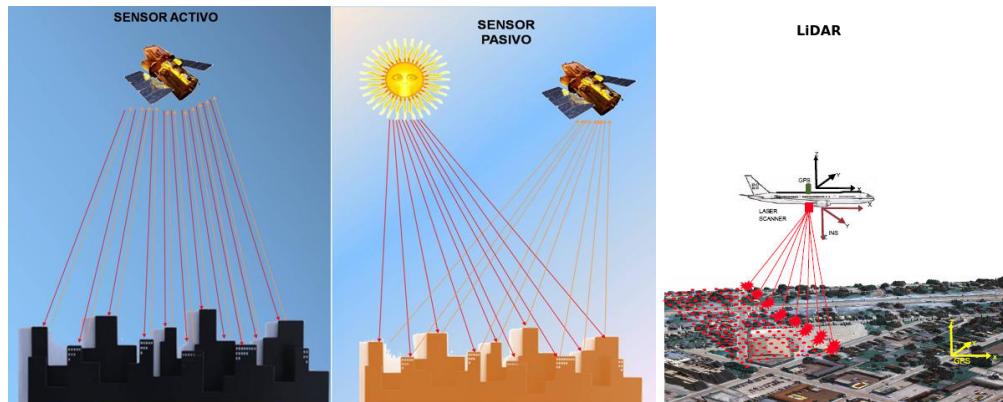


FIGURA 2.3: Tipos de sensores.

2.4. Teledetección en el medio ambiente

El término teledetección esta definida como la ciencia y arte de obtener información referente a la superficie terrestre sin entrar en contacto con ella. Esto se realiza detectando y grabando la energía emitida o reflejada para su procesamiento, análisis y aplicación de esa información [Sal02].

En los últimos años se han desarrollado bastantes aplicaciones en casi todas las áreas que involucra la tierra, debido a las grandes posibilidades y ventajas que presenta con la localización de espacios geográficos, observación de fenómenos temporales e integración

de resultados a los sistemas de información geográfica, reduciendo los costos en dinero y tiempo empleados en estudios sobre el terreno [BLMP06]. La aplicación de la teledetección en los recursos naturales se fundamenta en que los elementos del mismo tienen un respuesta espectral propia a los sensores remotos. Por ello, la teledetección espacial es empleada como complemento y no como sustituto a estudios ambientales por permitir realizarlos a escalas espaciales y temporales distintas a las que se acceden desde experimentos controlados, lo cuales son también necesarios e imprescindibles pero a veces insuficientes [PO11].

En la Figura 2.4 podemos observar el proceso completo de la teledetección. El sensor remoto montado en el satélite captura la información terrestre por medio de la energía solar. En una estación de recepción, la información capturada es transformada a imágenes para poder ser procesadas por el hombre en algún tipo de análisis.

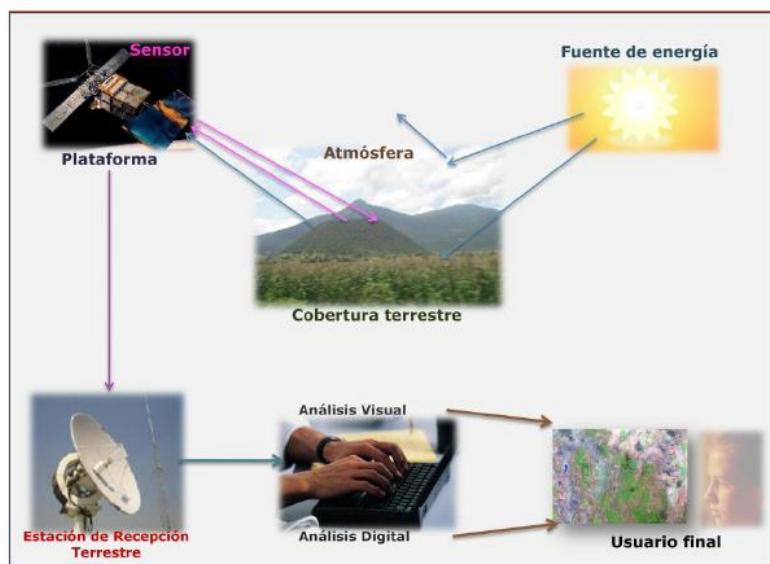


FIGURA 2.4: Teledetección [telb].

2.5. Resumen

La pérdida de los bosques provocan daños con consecuencias exponenciales al medio ambiente, ya que representan un factor fundamental en la estabilidad climática de la tierra. Las tierra esta cubierta por gases que dejan penetrar la energía solar, manteniendo temperaturas optimas para la vida. Algunos de los gases impiden el escape del calor hacia el espacio, a estos gases se los llaman gases de Efecto Invernadero (GEI). Las actividades

humanas producen en exceso los GEI, principalmente con dióxido de carbono (CO₂) a través de la deforestación y degradación en los bosques. La fotosíntesis compone un elemento fundamental en el proceso natural denominado ciclo del carbono, mitigando el CO₂ de la atmósfera con transformaciones del gas a materia orgánica en las plantas (biomasa), a esto se lo conoce como secuestro de carbono. El chaco paraguayo presenta una tendencia importante en el aumento de las tasas de deforestación, siendo entre los países que componen el Gran chaco americano el que presenta mayor porcentaje (86 %). En el 2011, el chaco paraguayo registro un promedio diario de 1402 hectáreas de bosques deforestados a causa de actividades humanas ligadas a la agricultura, silvicultura y ganadería, por ello la medición del balance de carbono en nuestro país resulta importante para controles del manejo del medio ambiente. Los inventarios forestales establecen relaciones entre reservas de carbono forestal y variables alométricas de los árboles para medir el contenido de carbono, presentando como principal dificultad la lentitud en el estudio de áreas extensas. En cambio, el empleo de procesamiento digital de imágenes satelitales junto con la teledetección nos brindan un dinamismo en el monitoreo a gran escala.

Capítulo 3

Procesamiento de imágenes satelitales

La teledetección presenta un principio base similar al de la visión, permitiendo mediante una fuente de energía, un objetivo o escena y un sensor, generar imágenes digitales que posibilitan resaltar aquellos elementos difíciles de percibir o ser distinguidos directamente a través de una imagen normal. El comportamiento característico que poseen los recursos naturales a sensores remotos, nos posibilita el empleo amplio de técnicas de procesamiento de imágenes provechosos para el logro de los objetivos en la investigación [DN].

Este capítulo consiste en brindar conceptos específicos utilizados por la metodología, posibilitando comprender la influencia de cada factor en el empleo de imágenes satelitales para la estimación de pérdida del contenido de carbono forestal.

3.1. Sensores Remotos

Los sensores remotos nos permiten obtener información de la superficie terrestre, soportados en diferentes plataformas (terrestre, aérea y satélite), mediante la captura de energías reflejadas o radiadas proveniente del sol (sensores pasivos) o del mismo sensor

(sensores activos) [Dua12]. La energía capturada es transformada en productos, con diversos y diferentes especificaciones, siendo las fotografiás áreas e imágenes de satélites las más conocidos.

3.1.1. El espectro electromagnético

Las longitudes de ondas son continuas, pero de igual modo se establecen un serie de bandas donde las radiaciones manifiestan un comportamiento similar, organizandolas de este modo en un espectro electromagnético [Ali10]. Las bandas más empleadas son las siguientes [Sal02]:

- **Espectro visible:** (400 nm a 700 nm) se denomina así por tratarse de la única radiación electromagnética que pueden percibir nuestros ojos, coincidiendo con las longitudes de onda en donde es máxima la radiación solar. Dentro de esta se distinguen tres bandas fundamentales: Azul (400 nm a 500 nm), verde (500 nm a 600 nm) y rojo (600 nm a 700 nm).
- **Infrarrojo próximo:** (700 nm a 1300 nm) se utiliza para discriminar masas vegetales y concentraciones de humedad.
- **Infrarrojo medio:** (1,3 um a 8 um) en esta franja se entremezclan los procesos de reflexión de la luz solar y de emisión de la superficie terrestre. El infrarrojo medio es muy utilizado para estimar el contenido de humedad en la vegetación y los focos de alta temperatura.
- **Infrarrojo lejano o térmico:** (8 um a 14 um) se detecta el calor de la mayoría de las cubiertas terrestres.
- **Microondas:** (a partir de 1 um) de gran interés por ser un tipo de energía transparente a la cubierta nubosa.

En la Figura 3.1 podemos observar como el sensor montado en una plataforma espacial capta la información terrestre en diferentes bandas de acuerdo a la longitud de onda.




FIGURA 3.1: Bandas capturadas por un satélite [telb].

3.1.2. Firmas espectrales

Las firmas espectrales consisten en la representación de energía reflejada con relación a las longitudes de ondas, consideradas sin el efecto atmosférico y medida en condiciones ideales del ángulo incidente. Las firmas espectrales ayudan a identificar los objetos en la superficie terrestre debido a que cada uno presenta una respuestapectral única [SRHS04].

En la Figura 3.2 se observa como cada objeto difiere de los demás en sus firmas espectrales.




FIGURA 3.2: Firmas espectrales de diferentes coberturas.

3.1.3. Resoluciones de un sensor

La resolución de un sensor se define como el menor cambio en la magnitud de entrada que puede ser apreciada en la magnitud de salida. El concepto de resolución implica al menos cuatro manifestaciones [Oje13]:

- **Resolución espacial:** es el tamaño que representa en el terreno una unidad de pixel de la imagen. Esta resolución tiene mucha importancia en la interpretación pues marca el nivel de detalle que ofrece. En la Figura 3.3 podemos observar que cuanto menor sea el tamaño del pixel, menor será también la probabilidad de que corresponda a un compuesto de dos o más áreas fronterizas.

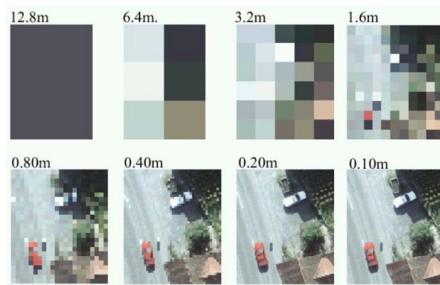


FIGURA 3.3: Resolución espacial [cha].

- **Resoluciónpectral:** indica el número y anchura de las bandas espectrales que puede discriminar el sensor. Un sensor será tanto más idóneo cuanto mayor número de bandas proporcione, ya que facilita la caracterizaciónpectral de las distintas cubiertas. En la Figura 3.4 se puede observar la comparación entre la resoluciónpectral de dos diferentes sensores espaciales.

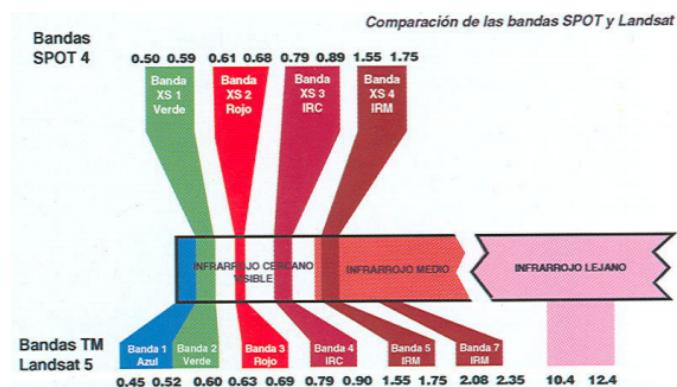


FIGURA 3.4: Resoluciónpectral igual a 3 para el sensor SPOT y 7 en el sensor Landsat [MD05].

- **Resolución radiométrica:** es la sensibilidad del sensor para detectar variaciones en la cantidad de energíaespectral recibida. La sensibilidad se expresa en bits e indica el número de los distintos niveles radiométricos que puede detectar un sensor. En la Figura 3.5 se puede observar diferentes resoluciones radiométricas.




FIGURA 3.5: Diferentes resoluciones radiométricas en imágenes satelitales .

- **Resolución temporal:** Este tipo de resolución se refiere al intervalo de tiempo entre muestras sucesivas de la misma zona de la cobertura terrestre. El ciclo de cobertura presentada por la Figura 3.6, está en función de las características orbitales de la plataforma, su velocidad, el ancho de barrido del sensor y las características de construcción del sistema.




FIGURA 3.6: Resolución temporal de 16 días [tel15].

3.2. Imágenes satelitales

Una imagen satelital es una función $f : (x, y, i) \rightarrow \{0, \dots, 2^r\}$. Cada (x, y, i) indica la posición (x, y) en la banda i , donde $i \in \{1, \dots, k\}$, $x \in \{0, \dots, fil\}$ e $y \in \{0, \dots, col\}$ para una matriz $fil \times col$, siendo k el número de bandas y r la resolución radiométrica en la imagen. Las imágenes satelitales son conocidas también como raster [Vás11] y se puede representar de forma matricial. La Figura 3.7 nos muestra los ejes de coordenadas espaciales (x, y) para cada plano que representan las bandas, pudiendo acceder a valor de la intensidad o nivel digital mediante el nivel digital $f(x, y, i)$.

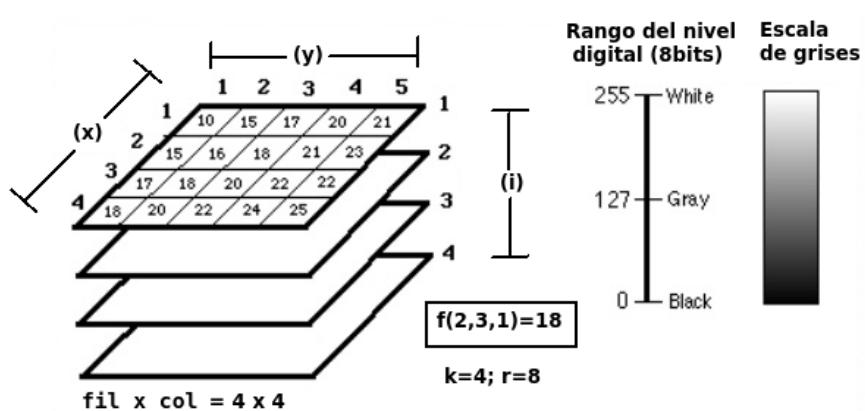


FIGURA 3.7: Valor digital en una imagen satelital de 4 bandas ($k = 4$) y resolución radiométrica $r = 8$.

3.2.1. Histogramas

El histograma de una imagen satelital, con niveles digitales en el rango de $[0, 2^r]$, es una función discreta $H(ND) = n_{ND}$, donde ND es el nivel digital y n_{ND} el número de pixeles en la imagen teniendo el nivel digital ND [Gon02].




FIGURA 3.8: Histograma de una imagen con niveles digitales de 0 a 255.

El histograma de una imagen satelital es una representación gráfica útil de la información contenida por las imágenes obtenidas a través de la percepción remota. En la Figura 3.8 podemos observar que para cada nivel digital va asociado un número de apariciones en la imagen.

Los analistas a menudo despliegan el histograma en cada banda, ya que proporciona una apreciación de la calidad de los datos que presenta una imagen. Por ejemplo si el contraste es bajo o muy alto (histogramas estrechos y amplios); si son multimodales responden a distintos tipos de coberturas detectadas (agua, humedales, tipos de vegetación, etc.), si en el histograma de la banda infrarroja cercana se encuentran picos desplazados hacia la derecha implicaría que existe una alta probabilidad de aparición vegetal en la imagen, entre otros análisis.

3.2.2. Combinación de bandas

La visualización de las imágenes de teledetección es mejor cuando se tiene una representación en colores, ya que el ojo humano percibe mejor las diferencias de color que los niveles de gris.

Las combinación de tres bandas a color en las imágenes satelitales recibe el nombre de imagen de color compuesta [com]. Las imágenes de las distintas bandas se pueden combinar entre ellas para producir una imagen en color real o en falso color en función de las bandas escogidas. Esto se hace asignando a cada uno de los canales (RGB) de la pantalla de ordenador, una banda en particular.

Las imágenes compuestas en color natural o real son combinaciones de las bandas 1 (azul), 2 (verde) y 3 (rojo) que coinciden aproximadamente con la gama visual del ojo humano, por lo que se parecen bastante a lo que esperaríamos ver en una fotografía normal en color. Las imágenes de color real tienden a presentar un bajo contraste y un aspecto algo borroso. Ello es debido a que la luz azul es más afectada que las demás por la dispersión atmosférica.

Otras combinaciones de bandas distintas, generan imágenes en falso color. La naturaleza de los objetos que se quieren investigar, determina la selección de las tres bandas a combinar [com]. A continuación se describe algunas combinaciones posibles con imágenes Landsat para la identificación visual de aspectos terrestres [LKC14]:

- **Bandas 3,2,1 (RGB):** Es una imagen de color natural. Refleja el área tal como la observa el ojo humano en una fotografía aérea a color.
- **Bandas 7,4,2 (RGB):** Permite discriminar los tipos de rocas. Ayuda en la interpretación estructural de los complejos intrusivos asociados a los patrones volcánico - tectónicos.
- **Bandas 5,4,2 (RGB):** Es una imagen que no refleja los patrones en colores naturales (falso color), por lo tanto las carreteras pueden ser rojas, el agua amarilla y la vegetación azul.

- **Bandas 7,3,1 (RGB):** Ayuda a diferenciar tipos de rocas, definir anomalías de color que generalmente son de color amarillo claro algo verdoso, la vegetación es verde oscuro a negro, los ríos son negros y con algunas coloraciones azules a celestes.

La Figura 3.9 muestra como es combinada las bandas (3,4,5) en los canales (R,G,B).

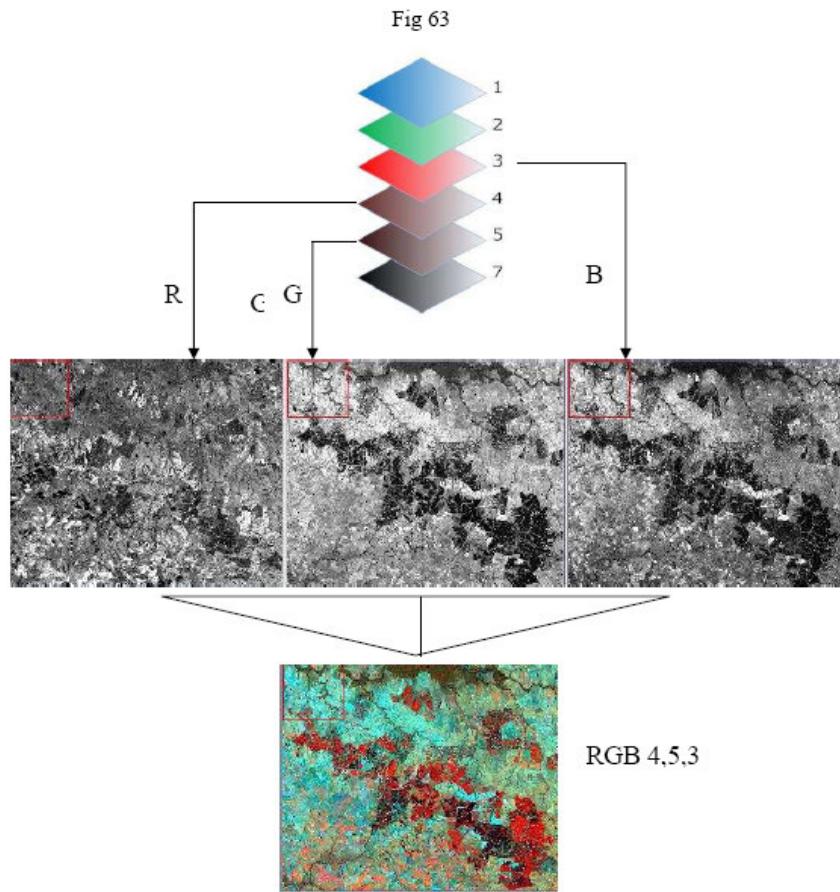


FIGURA 3.9: Combinación de bandas espectrales a través de los canales RGB.

3.3. Álgebra de mapas

El álgebra de mapas constituye un marco teórico en la mayor parte de las operaciones hechas con SIG a partir de raster. Pueden desarrollarse operaciones de muy diverso tipo que se clasifican [Tom90] en:

- **Operadores locales:** los operadores locales generan una nueva imagen a partir de una o más imágenes previamente existentes. Cada pixel de la nueva imagen recibe

un valor que es función de los valores de ese mismo pixel en las demás imágenes.

$$f_{1,2,3} = \rho(f_1, f_2, f_3) \quad (3.1)$$

Donde ρ representa a alguna función del tipo:

- Aritmético (suma, resta, multiplicación, división, raíz cuadrada, potencia, ...).
- Lógico (AND, OR, XOR, NOT).
- Relacional ($>$, $>=$, $<$, $<=$, $==$, $!=$).
- Trigonométrico (sen, cos, tan, ...).
- Condicional (si cumple la condición ejecuta la instrucción).

La Figura 3.10 nos muestra el proceso de operadores locales lógico y condicional. En el ítem (a), el operador lógico binariza la imagen si $DEM > 400$, mientras que en el ítem (b) el operador condicional clasifica la imagen en base a un rango ($600 - 650 = 1$; $650 - 700 = 2$; $700 - 750 = 3$; $750 - 800 = 4$).




FIGURA 3.10: Operadores locales condicional y lógico.

- **Operadores de vecindad:** adjudican a cada pixel un valor que es función de los valores de un conjunto de pixeles contiguas, en una o varias imágenes. El conjunto de pixeles contiguas al pixel, más ella misma constituye una vecindad.
 - Filtrado de imágenes: es el conjunto de técnicas que se aplican a las imágenes digitales con el objetivo de mejorar la calidad o facilitar la búsqueda de información.
 - Operadores estadísticos: calcula variables estadísticas (media, desviación típica, mínimo, máximo, entre otros.) a partir de los valores de todas los pixeles que forman la vecindad y lo adjudican al pixel central en la imagen de salida.

- Operadores direccionales: Permiten estimar un conjunto de parámetros relacionados con la ubicación de los diferentes valores dentro de la vecindad. Su utilidad primordial es el análisis de Modelos Digitales de Terreno (pendiente, orientación, curvatura, entre otros.)
- **Operadores de vecindad extendida:** son aquellos que afectan a zonas relativamente extensas, que cumplen determinado criterio pero cuya localización precisa no se conoce previamente. Por tanto el operador (algoritmo) debe determinar previamente cual es el área que cumple dichas características. En la Figura 3.11 podemos ver el resultado de haber aplicado un operador de vecindad extendida a partir de pixeles situados a distancias 25, 50, 75, 100, 125.

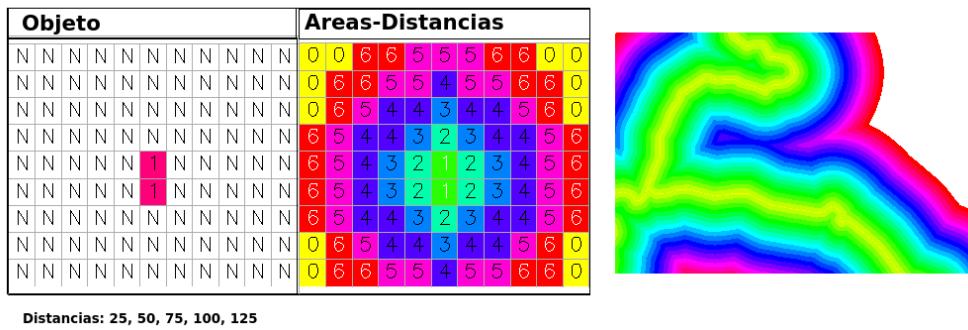


FIGURA 3.11: Áreas situadas a una distancia inferior a los valores umbrales 25, 50, 75, 100, 125.

- **Operadores de área o zonales:** son aquellos que calculan algún parámetro (superficie, perímetro, índices de forma, distancias, estadísticos) para una zona previamente conocida. Los valores pueden tratarse de diferentes niveles de una variable cualitativa o digitalizada e introducida por el usuario. En la Figura 3.12 se observa tres imágenes. La primera está clasificada en base a algún criterio (Variable cualitativa) y la otra con niveles digitales igual a la altitud (Variable cuantitativa), donde la imagen resultante corresponde a la altitud media para cada grupo.

Variable cualitativa	Variable cuantitativa	Resultado
23 23 23 20 20 20 20 20 20 20	402 402 401 401 400 400 395 392 386 384	394 394 394 383 383 383 383 383 383 383
23 23 23 23 20 20 20 20 20 20	402 402 401 401 400 400 394 393 393 390	394 394 394 394 383 383 383 383 383 383
23 23 23 23 20 20 20 20 20 20	402 401 401 400 394 394 390 386 380 376	394 394 394 394 383 383 383 383 383 383
23 23 23 23 23 20 20 20 20 20	401 401 400 395 396 398 390 386 380 373	394 394 394 394 394 394 383 383 383 383
23 23 23 23 23 23 20 20 20 20	401 400 396 394 386 388 385 380 375 371	394 394 394 394 394 394 383 383 383 383
23 23 23 23 23 23 20 20 20 20	400 396 394 389 395 396 394 390 375 370	394 394 394 394 394 394 383 383 383 383
23 23 23 23 23 23 23 20 20 20	397 395 390 387 392 393 390 377 375 370	394 394 394 394 394 394 383 383 383 383
23 23 23 23 23 23 23 20 20 20	397 393 390 387 392 393 390 377 373 370	394 394 394 394 394 394 383 383 383 383
23 23 23 23 23 10 10 20 20	397 383 380 387 382 383 380 377 374 371	394 394 394 394 381 381 381 381 383 383

FIGURA 3.12: Operador de área: Altitud media por áreas.

3.4. Índices de vegetación

Los índices de vegetación son transformaciones que implican efectuar una combinación matemática, entre los niveles digitales almacenados en dos o más bandas espectrales de la misma imagen, teniendo en cuenta el comportamiento radiométrico de la vegetación vigorosa para la elección de bandas [SZ05].

El estudio de las cubiertas vegetales mediante la teledetección se aborda tradicionalmente mediante la utilización de los denominados “índices de vegetación”, siendo el más utilizado el Índice de vegetación diferencial normalizada (NDVI) [SMIY00].

3.4.1. Índice de vegetación diferencial normalizada

Sea una función $ndvif : (x, y) \rightarrow [-1, 1]$ que determina el NDVI de la imagen satelital f en cada coordenada espacial (x, y) definida por la siguiente expresión:

$$ndvif(x, y) = \frac{f(x, y, IRc) - f(x, y, R)}{f(x, y, IRc) + f(x, y, R)} \quad (3.2)$$

Donde $R \in \{1, \dots, k\}$ representa la banda roja del espectro visible y $IRc \in \{1, \dots, k\}$ a la banda infrarroja cercana del espectro infrarrojo.

En la Figura 3.13 podemos observar como las plantas muestran un fuerte pico de absorción causados por los pigmentos fotosintéticos en longitudes de onda cercanas a los 700 micrones (banda roja), hecho que contrasta con una fuerte reflexión de las longitudes

de onda del infrarrojo cercano [Sal02]. Por su parte, los suelos desnudos se caracterizan por un incremento suavemente monotónico de la reflectancia, a medida que aumenta la longitud de onda [Sal02]. Estas características relevantes nos permiten elaborar varios tipos de análisis como extracción de índices.




FIGURA 3.13: Firma espectral de la vegetación [ndv].

3.4.1.1. Características del NDVI

El NDVI es un índice usado para estimar la cantidad, calidad y desarrollo de la vegetación por medio de sensores remotos instalados comúnmente desde la plataforma espaciales, es decir mide las condiciones de vigor vegetal de la planta, principalmente su contenido en clorofila [Sal02]. El objetivo del NDVI es la reducción de múltiples bandas a una sola, condensando la información más importante, en este caso la vegetación.

La principal ventaja del NDVI es su fácil interpretación, ya que sus valores varían entre -1 y +1, permitiendo conocer el estado de vigor vegetal en grandes superficies y detecta fenómenos de amplio rango [Sal02].

3.5. Análisis Multitemporal

El análisis multitemporal de imágenes satelitales consiste en el estudio de zonas determinadas mediante tomas hechas en diferentes tiempos. El factor temporal puede abordarse con un doble objetivo: por un lado reconstruir la variación estacional de la zona y por

otra parte la detección de cambios. Este último objetivo se enfoca en detectar cambios entre dos o más fechas alejadas en el tiempo, estudiando el dinamismo temporal de una determinada zona como por ejemplo: el crecimiento urbano, transformaciones agrícolas, entre otras [Sal02].

En el enfoque aplicado al estudio multitemporal resulta preciso abordar previamente una serie de tratamientos sobre las imágenes satelitales de cara a garantizar su comparabilidad, ya que existen factores naturales o las del sensor, que influyen desde la captura de información hasta su transformación final a niveles digitales que afectaría el análisis.

3.6. Correcciones a las imágenes satelitales

Las correcciones satelitales son el producto de aplicar un operador a una imagen satelital para la obtención de otra. Las correcciones están definida según la expresión:

$$f' = T[f] \quad (3.3)$$

Donde f es una imagen satelital de entrada, f' es la imagen corregida y T es un operador que realiza las correcciones a la imagen f , debido a fallos en los sensores, alteraciones en el movimiento del satélite o interferencias de la atmósfera [tela].

3.6.1. Corrección geométrica

Una imagen de satélite, al igual que las fotografías aéreas, no proporciona información georreferenciada; cada pixel se ubica en un sistema de coordenadas arbitrario de tipo fila-columna como los que manejan los programas de tratamiento digital de imágenes [Tro12].

El proceso consiste en dar a cada pixel su localización en un sistema de coordenadas estandard (UTM, lambert, coordenadas geográficas) para poder combinar la imagen de satélite con otro tipo de capas en un entorno SIG. El proceso obtiene una nueva imagen i' de alguna banda i de la imagen satelital, en la que cada columna corresponde con un valor de longitud y cada fila con un valor de latitud. En caso de que la imagen no

hubiese sufrido ningún tipo de distorsión, el procedimiento sería bastante sencillo, sin embargo una imagen puede sufrir diversos tipos de distorsiones.

Es necesario localizar puntos comunes de la imagen con puntos de control, como tarea inicial para la corrección geométrica, de manera a poder realizar una interpolación espacial y de los valores radiométricos [Tro12].

3.6.1.1. Interpolación espacial

La interpolación espacial consiste en determinar la relación geométrica entre las coordenadas del pixel de la imagen a corregir y sus coordenadas geográfica correspondientes. Utilizando los puntos comunes localizados, se plantea una ecuación de transformación mediante la cual se obtiene la posición de los píxeles en la imagen de salida, ilustrada en la Figura 3.14. Este proceso también es conocido como Georreferenciación.




FIGURA 3.14: Localización de puntos comunes y puntos de referencia.

3.6.1.1.1. Transformación usando ecuaciones polinómicas.

El método más utilizado para la transformación de imágenes satelitales es el de ecuaciones polinómicas. La transformación puede expresarse de la siguiente manera [Gui99]:

$$x'_i = \sum_{j=0}^l \sum_{e=0}^{l-j} a_{ij} x_i^j y_i^e \quad (3.4)$$

$$y'_i = \sum_{j=0}^l \sum_{e=0}^{l-j} b_{ij} x_i^j y_i^e \quad (3.5)$$

Donde x'_i e y'_i indica la coordenada en la imagen corregida para la banda i . El superíndice l indica el grado del polinomio de ajuste. Los coeficientes del polinomio a_i y b_i son hallados con el método de ajuste por mínimos cuadrados entre los puntos control y los puntos de la imagen. Siendo la ecuación lineal las más simple:

$$x'_i = a_0 + a_1 x_i + a_2 y_i \quad (3.6)$$

$$y'_i = b_0 + b_1 x_i + b_2 y_i \quad (3.7)$$

En distorsiones moderadas o en un área reducida, se utilizan transformaciones de primer orden, pudiendo corregir efectos de translación en x'_i e y'_i , cambios de escala y rotación. En distorsiones más importantes o en áreas extensas, es necesario una transformación de segundo orden. Este tipo de transformación agregan a diferencia del primer orden, correcciones a deformaciones locales. En la Figura 3.15 podemos observar las transformaciones con polinomios de primer y segundo orden.

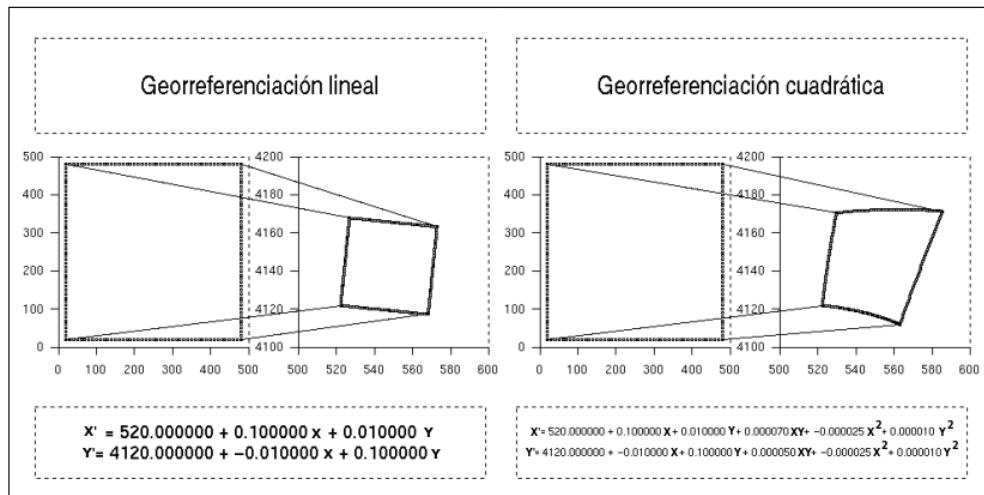


FIGURA 3.15: Interpolación espacial con polinomios de primer y segundo orden.

3.6.1.1.2. Calidad de la interpolación espacial

La calidad en la interpolación espacial y los puntos de control seleccionados η se calcula utilizando el promedio de los errores cuadráticos medios (RMS), que consiste en la

diferencia entre la coordenada transformada deseada para un punto de control y la coordenada real obtenida como salida.

$$RMS_i = \sqrt{\frac{\sum_{j=1}^{\eta} ((x'_{i,j} - x_{i,j})^2 + (y'_{i,j} - y_{i,j})^2)}{\eta}} \quad (3.8)$$

Donde los sub-índices (i, j) indican el punto de control j en la banda i de un total de η puntos de control. El valor de RMS elegido por referencia para corregir una imagen debe ser aproximadamente 0,5, y en lo posible nunca superar la unidad [Gui99].

La Figura 3.16 nos muestra la manera de como es calculado el RMS para un punto de control determinado.

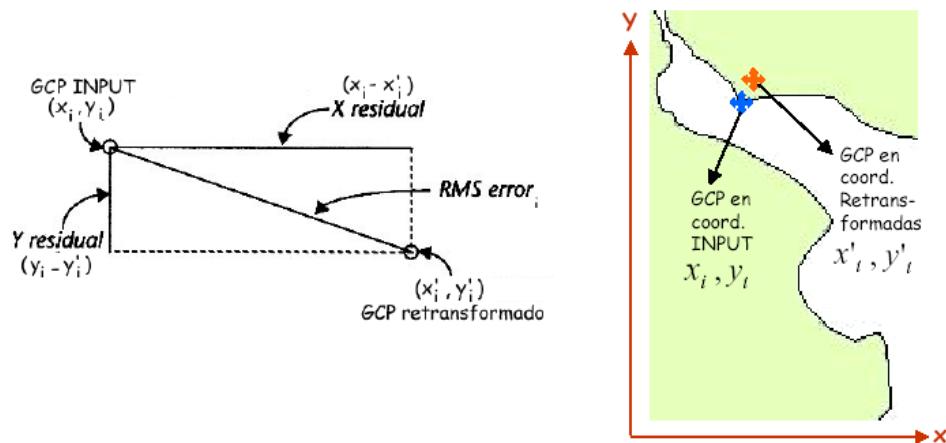


FIGURA 3.16: Error RMS de un punto de control (x, y) y su transformación (x', y') .

3.6.1.2. Interpolación de los valores radiométricos

La interpolación de los valores radiométricos es el traslado del nivel digital perteneciente a la imagen original a la imagen corregida espacialmente. La imagen original debe corresponderse con las coordenadas de la imagen corregida. La interpolación puede ser abordada por tres métodos diferentes:

- **Vecino más próximo:** situá en cada pixel de la imagen corregida el nivel digital (ND) del pixel más cercano en la imagen original. Constituye la solución más rápida y la que supone menor transformación en los niveles digitales originales.

Su principal inconveniente es que produce una distorsión en rasgos lineales en la imagen (fracturas, carreteras, caminos), que pueden aparecer en la corregida como lineales quebradas.

En la Figura 3.17 se observa el como los pixeles de la imagen transformada son trasladados a la imagen corregida a lado del vecino más próximo.




FIGURA 3.17: Interpolación Vecino más Cercano.

- **Interpolación bilineal:** Considera el valor de los 4 pixeles mas cercanos en la imagen de entrada para asignar el nuevo valor de la imagen de salida. Las ventajas son que no existe el efecto de escalones en los bordes pudiendo aparecer en el vecino superior izquierdo y ademas cuenta con mejor exactitud espacial. El método es utilizado a menudo cuando se cambia el tamaño de las celdas en los datos. La desventaja es que como los pixeles son promediados, algunos extremos de los valores de los datos pueden perderse. En la Figura 3.18 podemos observar los 4 pixeles cercanos tomados para la interpolación.




FIGURA 3.18: Interpolación Bilineal.

- **Convolución cúbica:** es similar a la interpolación bilineal pero considera niveles digitales de los 16 pixeles más próximos. El efecto visual es mejor, pero supone un volumen de cálculo mucho más elevado. La Figura 3.19 nos muestra los 16 pixeles tomados en el método.

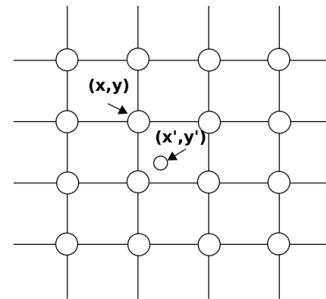


FIGURA 3.19: Convolución cúbica.

3.6.2. Corrección radiométrica

La corrección radiométrica se encarga de minimizar los desajustes producidos en el registro del valor digital en los pixeles de la imagen, de hecho en algunos casos las estaciones receptoras llevan a cabo algún tipo de corrección en el momento de recepción de la imagen. La corrección radiométrica implica por una parte la restauración de líneas o píxeles perdidos y por otra la corrección del bandedeo en la imagen [tela].




FIGURA 3.20: Fallos del sensor en la captura de la imagen.

La Figura 3.20 nos muestran tres tipos de errores radiométricos frecuentes, donde las líneas claras representan pixeles que no representan su nivel digital correcto a causa de la descalibración del sensor. Las líneas y pixeles negros son pixeles nulos que no pudieron ser convertidos a su nivel digital por fallos en el detector o transmisiones, como también por conversiones de la información analógica a digital.

3.6.2.1. Pixeles o líneas perdidas

Sea f' una imagen satelital con los pixeles corregidos, mediante estimaciones de la media entre los pixeles adyacentes. Donde cada nivel digital es calculado de la siguiente manera:

$$f'(x, y, i) = \text{ceiling}(1/2 \times [f(x - 1, y, i) + f(x + 1, y, i)]) \quad (3.9)$$

Donde $\text{ceiling}()$ representa la función techo (redondeo para arriba). No es recomendable utilizar los pixeles adyacentes de la misma línea (eje y) por que han sido captados por el mismo detector o banda que ha dado el fallo, por tanto son poco fiables [cor].

Las bandas de una imagen son de detectores diferentes y están altamente correlacionadas, por lo que se hace una modificación a la ecuación 3.9 teniendo en cuenta la banda i_* de la imagen satelital, donde $i_* \in [1, k]$, pudiendo utilizarse el valor del pixel faltante en una banda diferente para mejorar la estimación:

$$f'(x, y, i) = \text{ceiling}(dif_i + \frac{\sigma_i}{\sigma_{i_*}} \times [f(x, y, i_*) - dif_{i_*}]) \quad (3.10)$$

Donde σ_i representa la desviación típica de la banda i , σ_{i*} representa la desviación típica de la banda i_* y la variable dif_e , esta representada por la siguiente expresión:

$$dif_e = 1/2 \times [f(x - 1, y, e) + f(x + 1, y, e)] \quad (3.11)$$

Donde $e \in \{i, i_*\}$. En caso de que la imagen abarque un territorio amplio y cambiante resulta recomendable calcular las desviaciones típicas (σ_i y σ_{i*}) en un entorno cercano al pixel perdido.

Para detectar líneas perdidas se compara la media de los ND de una línea con las medias de las líneas anterior y posterior, para detectar pixeles perdidos se compara el valor de un pixel con los de los 8 pixeles.

3.6.2.2. Bandeado

El fenómeno del bandeado se debe a una mala calibración entre detectores y resulta especialmente visible en las zonas de baja radiancia (zonas marinas por ejemplo). El resultado es la aparición periódica de una banda más clara u oscura que las demás. Para corregir el bandeado se asume que, en caso de no haber error, los histogramas obtenidos por cada uno de los detectores serían similares entre sí y similares al histograma global de la imagen que se toma como referencia.

En primer lugar se calculan los coeficientes m y s para una corrección lineal de cada uno de las bandas.

$$m = \frac{\sigma_i}{\sigma_{i*}} \quad (3.12)$$

$$s = \mu_i - m \times \mu_{i*} \quad (3.13)$$

Siendo μ_i y μ_{i*} las medias para la banda i e i_* . Donde cada nivel digital de la imagen satelital f' es calcula de la siguiente manera:

$$f'(x, y, i) = m \times f(x, y, i) + s \quad (3.14)$$

En Figura 3.21 podemos observar el histogramas de una banda corregida en función a las demás bandas pertenecientes a una imagen satelital.

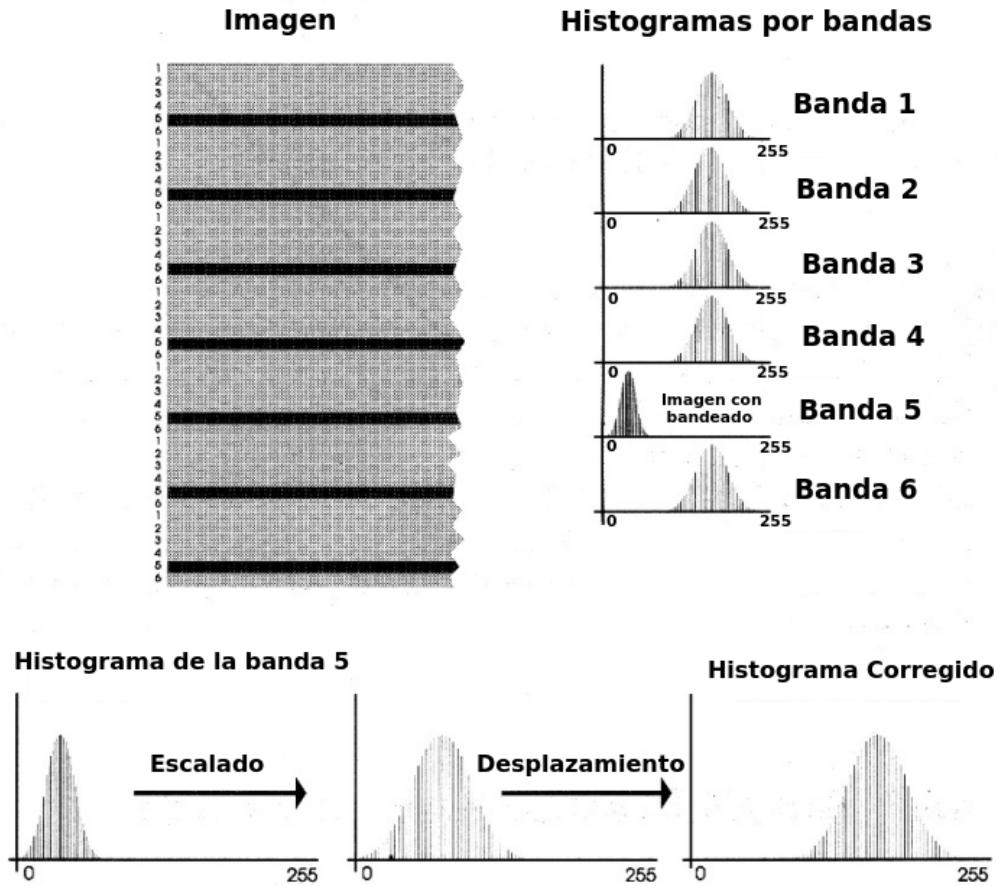


FIGURA 3.21: Proceso de corrección del bandeo.

3.7. Proceso de detección de cambios

En los métodos comunes de detección de cambios se asigna un valor correspondiente al grado de cambio sobre cada pixel, independientemente del resto de la imagen satelital. En estos métodos se considera el pixel como unidad básica (álgebra de mapas) para aplicar las correspondientes operaciones matemáticas asociadas a cada algoritmo.

Los métodos de comparación, generan una imagen (índice de cambios) que representa el grado de cambio entre dos situaciones temporales; los píxeles de la imagen resultante, contienen una variable continua de tipo cuantitativo (Niveles digitales), por lo que se requieren técnicas que los conviertan en variables cualitativa (Categorías) [MG13].

3.7.1. Normalización Radiométrica

La normalización radiométrica pretende optimizar el proceso de comparación mejorando la semejanza entre imágenes. La distintas respuestas espectrales que presentan las coberturas vegetales en diferentes estaciones del año o condiciones ambientales en el momento de la captura hace necesario un procedimiento adicional que iguale los píxeles en relación a contraste y brillo entre imágenes. La normalización mediante parámetros estadísticos de las imágenes fue utilizado ya que representa un método óptimo para comparar imágenes satelitales de una secuencia multitemporal donde el cambio es reducido [MR99].

Una secuencia multitemporal esta definido por $\{f_t\}_{t \in \mathbb{N}}$, que representa una secuencia de imágenes satelitales de la misma zona en diferentes tiempos. En la Figura 3.22 podemos observar el histograma de la secuencia de imágenes (f_t, f_{t_*}) y el histograma de la imagen resultante luego de la normalización (f_t^{Norm}).




FIGURA 3.22: Histogramas de la la banda i en los tiempos t, t_* junto con el de la imagen normalizada.

Las distintas bandas de una imagen satelital presentan un comportamiento con distribución normal en sus histogramas [MG13], por lo que teniendo variables tipificadas $Z_{i,t}$ para la imagen satelital f_t y Z_{i,t_*} para la imagen satelital f_{t_*} , ambos de la banda i , es posible definirlos en una distribución normal estándar del tipo $N(0, 1)$ (media 0 y desviación 1) según la expresión:

$$Z_{i,t} = \frac{f_t(x, y, i) - \mu_{i,t}}{\sigma_{i,t}} \quad (3.15)$$

$$Z_{i,t_*} = \frac{f_{t_*}(x, y, i) - \mu_{i,t_*}}{\sigma_{i,t_*}} \quad (3.16)$$


Donde $\mu_{i,t}, \sigma_{i,t}$ representa la media y desviación para f_t en la banda i , $\mu_{i,t_*}, \sigma_{i,t_*}$ representa la media y desviación para f_{t_*} en la banda i . Igualando las ecuaciones 3.15 y 3.16:

$$\frac{f_t(x, y, i) - \mu_{i,t}}{\sigma_{i,t}} = \frac{f_{t_*}(x, y, i) - \mu_{i,t_*}}{\sigma_{i,t_*}} \quad (3.17)$$

Para su aplicación práctica se puede transformar el nivel digital $f_t(x, y, i)$ perteneciente a la banda i de la imagen satelital f_t , para que se asemeje al $f_{t_*}(x, y, i)$ perteneciente a la banda i de la imagen satelital f_{t_*} . Siendo $f_t^{Norm}(x, y, i) \simeq f_{t_*}(x, y, i)$ la imagen normalizada definida por una relación lineal entre las dos distribuciones con la siguiente expresión:

$$f_t^{Norm}(x, y, i) = \mu_{i,t_*} + \frac{\sigma_{i,t_*}}{\sigma_{i,t}} \cdot (f_t(x, y, i) - \mu_{i,t}) \quad (3.18)$$

La transformación obtiene histogramas parecidos, logrando de este modo mayor semejanza para el proceso de comparación multitemporal. En la Figura 3.23 podemos observar como en cada pixel de la imagen f_t y f_{t_*} se igualan las variables tipificada $Z_t = Z_{t_*}$, de manera a obtener una ecuación 3.18 que asemeje cada pixel de la imagen f_t a la imagen f_{t_*} . La normalización genera una imagen f_t^{Norm} semejante a f_{t_*} .



$$\frac{f_t(x, y, i) - \mu_{i,t}}{\sigma_{i,t}} = \frac{f_{t_*}(x, y, i) - \mu_{i,t_*}}{\sigma_{i,t_*}}$$

$$f_t^{Norm}(x, y, i) \simeq f_{t_*}(x, y, i)$$

$$f_t^{Norm}(x, y, i) = \mu_{i,t_*} + \frac{\sigma_{i,t_*}}{\sigma_{i,t}} \cdot (f_t(x, y, i) - \mu_{i,t})$$

FIGURA 3.23: Proceso de normalización radiometrica entre una imagen satelital en el tiempo t y t_* .

3.7.2. Comparación multitemporal

La comparación parte de un par de imágenes semejantes que abarcan la misma zona de estudio, siguiendo una secuencia multitemporal. Las operaciones más utilizadas son [Chu98]:

- **Diferencia de imágenes:** es el método más simple, fácil de interpretar y directo, ya que consiste en una diferencia algebraica entre los niveles digitales (ND) inicial y final para la obtención de un índice (I_{dif}). Normalmente es realizada combinada con extracciones de índices espectrales.

$$I_{dif} = f_{t_*} - f_t \quad (3.19)$$

Donde $t_* \neq t$.

- **Ratio:** se obtiene aplicando la operación de cociente, entre los niveles digitales (ND) inicial y final para la obtención de un índice (I_{ratio}). Podría generar mejores resultados pero no se ajusta a una distribución normal.

$$I_{ratio} = \frac{f_{t_*}}{f_t} \quad (3.20)$$

Estas dos operaciones generan una imagen con índices de cambios I_c a partir de cada conjunto de datos multitemporal, dando lugar a tantos mapas de cambios como bandas/capas se consideren.

3.7.3. Criterios de decisión

El resultado de los cálculos es una imagen en donde el valor de salida indica el grado de cambio, desde la mayor pérdida a la mayor ganancia, en una escala gradual. Si se pretende generar una imagen binaria (cambio/estable), es preciso señalar un umbral que delimita ambas categorías en las imágenes. Ahí se plantea un problema de difícil solución ya que no existen criterios de aplicación general.

Si el cambio abarca un sector importante de la imagen, el histograma de la imagen de cambios (I_c) debiese mostrar un perfil bimodal, lo que permitiría establecer umbrales

naturales de cambio, aunque esta situación no es muy habitual, ya que los cambios en la naturaleza no suelen producirse de modo abrupto [MG13].

Si es necesario establecer un umbral para separar las áreas de cambio, puede optarse por señalar algún criterio estadístico, como la media y la desviación típica de una serie de píxeles elegidos aleatoriamente. En ocasiones se ha propuesto utilizar unas áreas de entrenamiento para calcular que rango de desviación se podía considerar límite para píxeles estables, aplicando luego ese valor al conjunto de la imagen [TL88].

3.7.3.1. Discriminación de las zonas de cambio

La comparaciones multitemporales generan indices que corresponden a variables cuantitativas, por lo que la aplicación de métodos que discriminan las zonas, en tipos de cambios, permitirán un análisis mas específico sobre la imagen satelital.

Sea $B : I_c \longrightarrow \{0, 1\}$ una función que binariza una imagen en base a un Umbral U :

$$B(I_c) = \begin{cases} 1 & \text{si se cumple que } I_c \geq U \\ 0 & \text{en cualquier otro caso} \end{cases} \quad (3.21)$$

La ecuación 3.21 genera una máscara binaria de cambios (0, No Cambio; 1, Cambio) aplicando un umbral (U) específico sobre la imagen resultante del proceso de comparación multitemporal [Sin89]. Son fácilmente implementables en procesos de carácter automático/semitomático. Partiendo de la hipótesis de que el porcentaje de cambios es muy reducido, los valores correspondientes se encuentran situados en los extremos del histograma de frecuencias [ERdR04]. Es preciso señalar un umbral que delimita ambas categorías (cambio/no cambio) a partir del índice de cambios [RAAKR05] para generar una máscara.

El método de discriminación basado en los parámetros estadísticos del índice de cambio entre la secuencia temporal de imágenes tiene la siguiente expresión [RGGSCO⁺10]:

$$U = \mu_{I_c} \pm n \times \sigma_{I_c} \quad (3.22)$$

Donde los dos umbrales de cambio/no cambio (U) se estima en función a la media (μ_{I_c}) y desviación (σ_{I_c}) de la imagen de Indice de cambio (I_c), junto con un coeficiente de tolerancia n asignado en base a la fiabilidad de los datos. Los resultados se clasifican en función de n ; alta probabilidad de cambio ($n \geq 2$) y zonas de media probabilidad de cambio ($1 < n < 2$) [ERdR04].

3.7.4. Filtrado

Los filtros constituyen unos de los principales métodos del procesamiento digital de imágenes . Pueden usarse para distintos fines, pero siempre, el resultado sobre cada pixel depende de los píxeles en su entorno. Tiene como objetivos:

- **Suavizar la imagen:** reducir las variaciones de intensidad entre píxeles vecinos.
- **Eliminar ruido:** modificar aquellos píxeles cuyo nivel de intensidad es muy diferente al de sus vecinos.
- **Realzar la imagen:** aumentar las variaciones de intensidad, allí donde se producen.
- **Detectar bordes::** detectar aquellos píxeles donde se produce un cambio brusco en la función intensidad.

3.8. Resumen

La utilización de imágenes satelitales implica un pre-procesamiento adicional, diferente a las que se le realiza a imágenes normales. Estos pre-procesamientos van ligados a resoluciones, firmas espectrales y tipos de imágenes satelitales propias del sensor espacial que captura la información. En este capítulo se describen conocimientos previos para aplicar análisis multitemporales y detección de cambio en imágenes de satélite que componen piezas fundamentales en la metodología propuesta.

Capítulo 4

Materiales y Metodología

En este capítulo se describirán los materiales a utilizar en la elaboración de la metodología, así como también aquellos a utilizar en las diversas pruebas y validaciones. Además se presentan las diversas características de las imágenes satelitales a ser empleados en el estudio. La metodología nos presenta los diferentes procesos o módulos necesarios para la estimación de pérdida de carbono.

4.1. Materiales

Un grupo de imágenes fueron utilizadas para los diferentes estudios y procedimientos de la metodología, tales como:

- Imágenes satelitales Landsat.
- Imágenes Campos Continuos de Vegetación (VCF).
- Imagen Mapa global de carbono - Paraguay.
- Paraguay Forest Change Product.

En el procesamiento e implementación de algoritmos fueron utilizados dos aplicaciones:

- GRASS.
- Quantum GIS.

A continuación se hablarán con mayor detalle de los elementos citados.

4.1.1. Imágenes

En este apartado se pretende brindar las diferentes características que presentan cada tipo de imagen utilizada en este trabajo..

4.1.1.1. Landsat

Landsat representa la colección más larga y continua en el mundo de imágenes satelitales con resoluciones moderadas [lan13]. Cuatro décadas de imágenes proporciona un recurso único para personas que trabajan en la agricultura, geología, silvicultura, ordenación territorial, educación, cartografía e investigación del cambio global, como también en respuesta de emergencias y operaciones de socorro.

Las imágenes están disponibles desde 1972 generados por una serie de 6 satélites Landsat. Estos satélites han sido un componente importante del Programa de Observación de la tierra perteneciente a la NASA, con tres sensores primarios evolucionando a lo largo de treinta años: MSS (Multi-spectral Scanner), TM (Thematic Mapper), y ETM+ (Enhanced Thematic Mapper Plus). El 11 de febrero del 2013 fue lanzado el Lansadt 8 correspondiendo al futuro de los satélites Landsat con dos nuevo sensores, Operational Land Imager (OLI) y el Thermal Infrared Sensor (TIRS). La Tabla 4.1 nos muestra las diferentes resoluciones de los sensores Landsat.

Landsat	Resoluciones				
	Espacial	Espectral	Radiométrica	Temporal	Sensor
1	79x79 m ²	5 bandas	6 bits	18 días	MSS
2	79x79 m ²	5 bandas	6 bits	18 días	MSS
3	79x79 m ²	5 bandas	6 bits	18 días	MSS
4	30x30 m ²	7 bandas	8 bits	16 días	TM
5	30x30 m ²	7 bandas	8 bits	16 días	TM
6	30x30 m ²	8 bandas	8 bits	16 días	ETM+
7	30x30 m ²	8 bandas	8 bits	16 días	ETM+
8	30x30 m ²	9 bandas	12 bits	16 días	OLI/TIRS

TABLA 4.1: Resoluciones de los satélites Landsat.

El Sistema de Referencia Mundial Landsat-2 (WRS-2: Landsat Worldwide Reference System-2) provee un esquema de indexación para el patrón de repetición de la trayectoria orbital terrestre seguida por las plataformas espaciales Landsat 4, 5 y 7 sobre los 16 días de su repetitivo ciclo orbital [els]. El original WRS (WRS-1) fue diseñado para las

misiones Landsat 1, 2, y 3, las cuales se movieron en una órbita más alta. El actual WRS-2 fue diseñado para la órbita a 705 Km usada para las últimas misiones. En la Figura 4.1 podemos observar los índices (Path y Row) en el momento de la obtención de una imagen satelital Landsat para una zona.

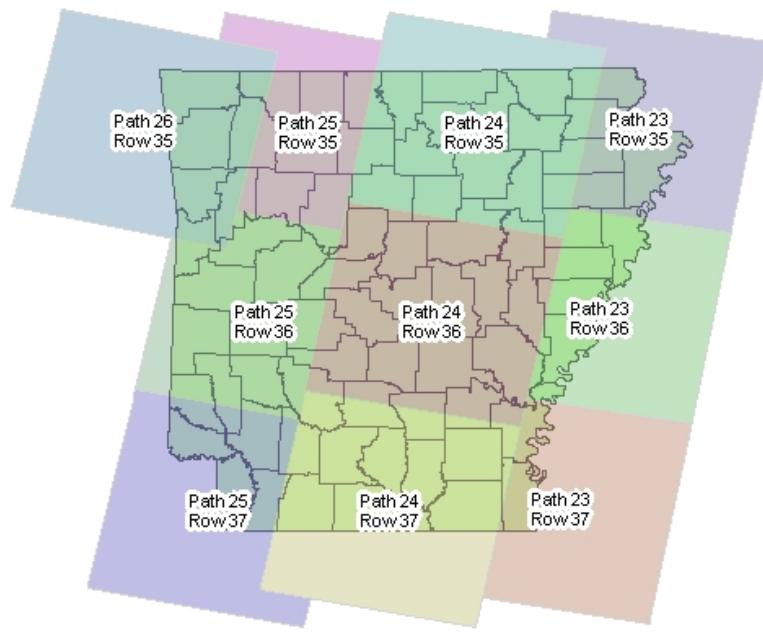


FIGURA 4.1: Ejemplo WRS-2 Path/Row

El Servicio Geológico de los Estados Unidos (USGS) es una agencia científica de los Estados Unidos, el cual proveen un producto llamado L1T (Level 1 Terrain Corrected) que implica las imágenes Landsat con datos pre-procesados para una corrección radiométrica sistemática y corrección geométrica mediante la incorporación de puntos de control en tierra. Estos productos están en la Web de forma gratuita [lan13].

4.1.1.2. Campos Continuos de Vegetación (VCF)

Las imágenes VCF contienen estimaciones proporcionales para los tipos de cobertura vegetal: vegetación leñosa, vegetación herbácea y suelo desnudo. El producto se deriva de las siete bandas del sensor MODerate-resolution Imaging Spectroradiometer (MODIS)

a bordo del satélite Terra, perteneciente a la NASA. El esquema de clasificación continuo del VCF puede representar áreas terrestres heterogéneas mejor que los esquemas tradicionales de clasificación discreta. Los sistemas de clasificación tradicionales indican donde se concentran los tipos de cobertura del suelo. El VCF posee un resolución espacial de 250x250 metros cuadrados y la colección de imágenes se encuentra disponible gratuitamente en la Web [gl215]. La Figura 4.2 nos presenta un imagen, con diferentes tonalidades de color, para los porcentajes de vegetación y los niveles digitales del agua como pixeles nulos.

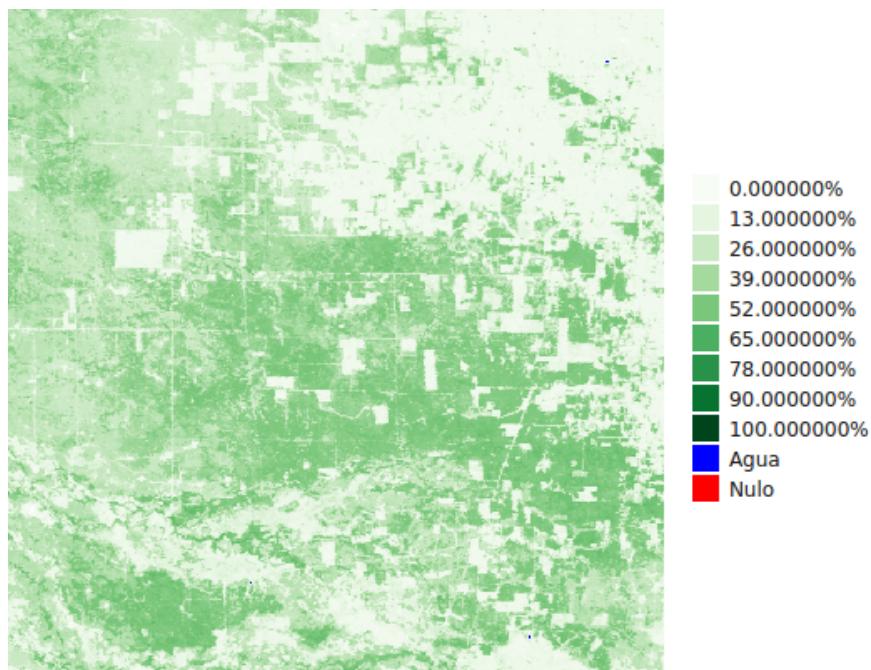


FIGURA 4.2: Imagen VCF con diferentes tonalidades de color acuerdo al porcentaje de vegetación.

4.1.1.3. Mapa global de carbono - Paraguay

El mapa global de carbono [SHB⁺¹¹] nos provee la densidad de carbono, expresada en toneladas de carbono por hectárea, del área ocupada por un pixel. El mapa fue elaborado para la década de los 2000. En la actualidad existen diferentes mapas de carbono a nivel mundial [SHB⁺¹¹]. La Figura 4.3 representa el mapa global de carbono disponible para el Paraguay.

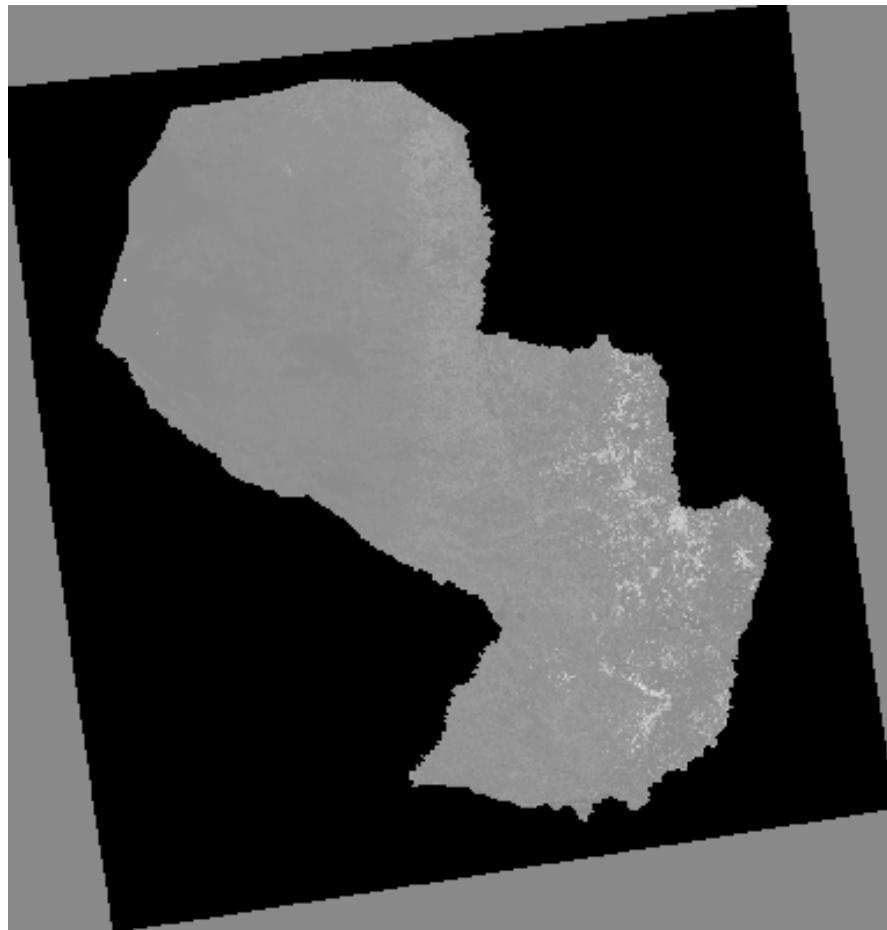


FIGURA 4.3: Mapa Global de Carbono - Paraguay

4.1.1.4. Paraguay Forest Change Product

El Paraguay Forest Change Product (PFCP) muestra donde ocurrió la deforestación en Paraguay durante 1990-2000. El PFCP fue elaborado a partir de las imágenes Landsat TM y ETM+, identificando seis clases; bosque atlántico, Chaco bosques, el agua, no forestales y la deforestación. El producto puede ser utilizado para determinar procesos y patrones de cambio en la cubierta forestal. En la Figura 4.4 se puede observar el PFCP (disponible gratuitamente [[gl215](#)]). En la Tabla 4.2 se describe la representación de cada nivel digital en dicha imagen. .

Valor digital	Representación	Color sugerido
1	Bosque Atlántico	Verde
2	Bosque Chaqueño	Verde Claro
3	No Bosque	Aqua
4	Aqua	Azul
5	Pérdida Bosque Atlántico	Rojo
6	Pérdida Bosque Chaqueño	Purpura Claro

TABLA 4.2: Representación del valor digital en la imagen PFCP.

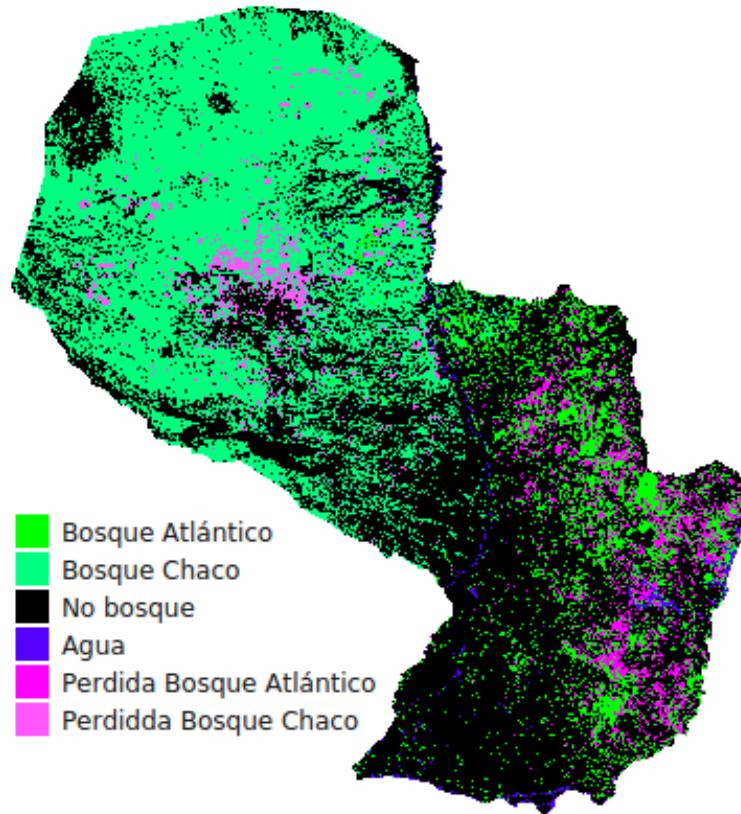


FIGURA 4.4: Paraguay Forest Change Product

4.1.2. Aplicaciones

Sistemas de información geográfica fueron utilizados para la manipulación de imágenes satelitales, como también para diseñar e implementar los algoritmos utilizados en la metodología propuesta. A continuación se describen las aplicaciones utilizadas.

- **GRASS:** es un software SIG bajo licencia GPL (software libre) [osg15]. El software soporta información tanto raster como vectorial y posee herramientas de procesado digital de imágenes. Esta disponibles principalmente para plataformas Linux.

- **Quantum GIS:** es un SIG de código libre para plataformas GNU/Linux, Unix, Mac OS, Microsoft Windows y Android. La principal diferencia con el GRASS es la interfaz amigable con que cuenta y la facilidad de integración con nuevas funciones espaciales desarrollados por los usuarios [QGI15].

4.2. Metodología

Los datos de entrada son las imágenes Landsat pre-procesadas (correcciones geométricas y radiométricas) de manera a disminuir los errores de localización e intensidad de los niveles digitales causados por distintos factores (sección 3.6). Las imágenes Landsat 8 no deben ser mezcladas con imágenes de otro sensor del mismo satélite, ya que esta posee una resolución radiométrica de 16 bits y las demás son capturadas a 8 bits. Las bandas utilizadas corresponde a la infrarroja cercana y roja.

En la Figura 4.5 podemos observar que a partir de las banda infrarroja cercana y roja ($f_t(x, y, IRc)$; $f_t(x, y, R)$, $f_{t_*}(x, y, IRc)$; $f_{t_*}(x, y, R)$) de una secuencia multitemporal, donde $t < t_*$, es posible obtener una mascara de perdida forestal MPF y su cuantificación (CCP) en toneladas de carbono perdidos ($ton\ C$) una vez pasado por los procesos de detección de cambio forestal y estimación de pérdida de carbono Forestal.

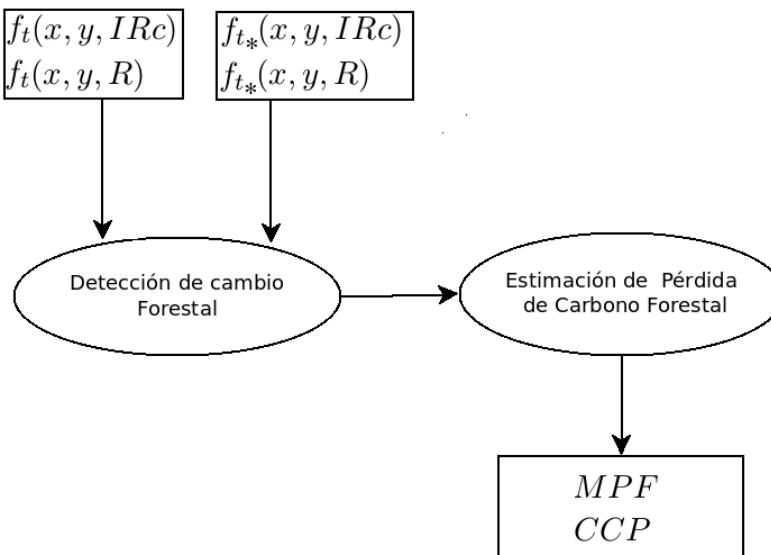


FIGURA 4.5: Diagrama de flujo. Metodología propuesta

4.2.1. Detección de cambio Forestal

La detección de cambio cumple un papel fundamental en la metodología ya que nos permite categorizar el cambio en la secuencia temporal estudiada. Este proceso presenta una metodología automatizada a través del cálculo de parámetros estadísticos extraídos de las imágenes satelitales y el uso de variables determinadas en un previo análisis del comportamiento espectral observados en la cobertura vegetal de prueba.

4.2.1.1. Detección de cambio

En este proceso se detecta el cambio entre dos tiempos de imágenes satelitales. El resultado esperado constituye una máscara de pérdida (MP) entre las series temporales de imágenes comparadas.

4.2.1.1.1. Comparación Multitemporal

El siguiente paso después de haber equiparado radiométricamente (sección 3.7.1) las imágenes consiste en la comparación multitemporal, permitiendo obtener un índice de cambio (variable cuantitativa) en cada pixel resultante. El método de diferencia de imágenes es utilizada debido a que el método Ratio no se ajusta a una distribución normal, se asume que el cambio es reducido y por ende están ubicados hacia los extremos del histograma de la imagen con los índices de cambio I_c , condición clave para la umbralización estadística. La comparación es realizado sobre la imagen con los NDVI de cada serie temporal a modo a resaltar la vegetación y simplificar la cantidad de bandas utilizadas, observando a su vez que los datos estables serán próximos a 0 gracias a la semejanza existente entre los pixeles.

4.2.1.1.2. Umbral estadístico

Los criterios de decisión propuesto en la sección 3.7.3.1 asignan valores de cambio/no cambio en función a un umbral. Estos criterios permiten convertir los índices de cambios a valores cualitativos que representan una máscara de cambio (MC). El método basados en parámetros estadísticos es escogido por su sencillez y coherencia con el método de

comparación multitemporal aplicada. Los niveles digitales de MC están definidos por la siguiente expresión:

$$MC(x, y) = \begin{cases} 1 & \text{si se cumple que } \mu_{I_c} - n \times \sigma_{I_c} < I_c(x, y) < \mu_{I_c} + n \times \sigma_{I_c} \\ 0 & \text{cualquier otro caso} \end{cases} \quad (4.1)$$

En la Figura 4.6 se puede observar una linea roja y verde, que determinan los límites para los cuales los índices no son considerados pixeles de cambio (pixeles que no variaron con respecto al tiempo). La variable de fiabilidad n es elegida en base a la probabilidad de cambio deseado para la detección (sección 3.7.3.1).

$$\mu_{I_c} - n \times \sigma_{I_c} < I_c(x, y) < \mu_{I_c} + n \times \sigma_{I_c}$$




FIGURA 4.6: Umbrales que binarizan los índices de cambios I_c .

Los pixeles que sufrieron pérdida estarán definidos por una máscara MP con las siguiente expresión:

$$MP(x, y) = \begin{cases} 1 & \text{si se cumple que } I_c(x, y) < \mu_{I_c} - n \times \sigma_{I_c} \\ 0 & \text{cualquier otro caso} \end{cases} \quad (4.2)$$

4.2.1.1.3. Iteración

Si dos imágenes se consideran semejantes, los cambios producidos en el terreno afectan a la radiometría registrada en las imágenes, y por tanto, en los parámetros estadísticos

que las definen.

En la normalización radiométrica los cambios introducen ruido [MG13], ya que el proceso busca que los pixeles de una banda de imágenes satelitales en diferentes tiempos sean semejantes y el cambio estaría influyendo en la correlación entre los pixeles que verdaderamente no sufrieron cambio. Si el área de todos los pixeles con cambio es mayor, la influencia en la normalización será mayor y por ende afectara la precisión en la detección de cambios. En vista al problema, mediante una normalización radiométrica iterativa se pretende minimizar dicha influencia, donde los parámetros estadísticos (μ, σ) utilizados constituyen los pixeles sin cambios.

La Figura 4.7 nos presenta el ciclo de procedimientos para la detección de cambio, donde a partir de la secuencia de imágenes satelitales en las bandas infrarroja cercana y roja ($f_t(x, y, IRc)$; $f_t(x, y, R)$, $f_{t*}(x, y, IRc)$; $f_{t*}(x, y, R)$) son calculados los parámetros estadísticos ($\mu_{i,t}; \sigma_{i,t}, \mu_{i,t*}; \sigma_{i,t*}$) para las imágenes.




FIGURA 4.7: Diagrama de flujo. Detección de Cambio.

Esos parámetros son utilizados para normalizar radiométricamente las bandas del tiempo t_* , en semejanza a las bandas de la imagen satelital del tiempo t , así determinar la imagen con los índices de cambios (I_c) una vez calculados los NDVI ($ndvi_{f_t}, ndvi_{f_{t*}}$). La máscara de cambio (MC) es el resultado de pasar por los umbrales estadísticos (sección 4.2.1.1.2). La iteración ($iter$) continua si la media del I_c actual es de magnitud

similar a la registrada en la anterior. Se define la función lógica *continuar*:

$$\text{continuar}(\mu_{I_c^{iter}}, \mu_{I_c^{iter-1}}) = \begin{cases} \text{falso} & \text{si se cumple que } \mu_{I_c^{iter}} - \mu_{I_c^{iter-1}} \leq \epsilon \\ \text{verdadero} & \text{en cualquier otro caso} \end{cases} \quad (4.3)$$

Siendo ϵ un error de aproximación. Si el proceso de iteración debe continuar, el cálculo de los parámetros estadísticos debe realizarse según el Algoritmo 1.

Algoritmo 1 Función que calcula los parámetros estadísticos.

```

1: Función PARAMETROS( $f_t(x, y, R)$ ,  $f_t(x, y, IRc)$ ,  $MC$ )
2:    $sumR = 0$  // Variable auxiliar sumatoria
3:    $sumIRc = 0$  // Variable auxiliar sumatoria
4:    $nT = 0$  // Número de pixeles sin cambio
5:   para  $x \leftarrow 0, fil$  hacer
6:     para  $y \leftarrow 0, col$  hacer
7:       si  $MC(x, y) = 1$  luego
8:          $sumR = sumR + f_t(x, y, R)$ 
9:          $sumIRc = sumIRc + f_t(x, y, IRc)$ 
10:         $nT = nT + +$ 
11:      fin si
12:    fin para
13:  fin para
14:   $\mu_{R,t} = sumR/nT$ 
15:   $\mu_{IRc,t} = sumIRc/nT$ 
16:   $sumR = 0$ 
17:   $sumIRc = 0$ 
18:  para  $x \leftarrow 0, fil$  hacer
19:    para  $y \leftarrow 0, col$  hacer
20:      si  $MC(x, y) = 1$  luego
21:         $sumR = sumR + (f_t(x, y, R) - \mu_{R,t})^2$ 
22:         $sumIRc = sumIRc + (f_t(x, y, IRc) - \mu_{IRc,t})^2$ 
23:      fin si
24:    fin para
25:  fin para
26:   $\sigma_{R,t} = \sqrt{\frac{1}{nT - 1} \times sumR}$ 
27:   $\sigma_{IRc,t} = \sqrt{\frac{1}{nT - 1} \times sumIRc}$ 
28:  retornar  $[\mu_{R,t}, \mu_{IRc,t}, \sigma_{R,t}, \sigma_{IRc,t}]$ 
29: fin Función

```

Cada valor de pixel, de las bandas en cada imagen satelital, es utilizado en el cálculo si no representa un cambio en la máscara de cambio MC . El proceso de iteración finaliza retornando una un máscara de pérdida MP según la ecuación 4.2.

En la Figura 4.8 podemos observar que a partir de la mascara de cambio obtenido en la primera iteración, los parámetros estadísticos para la iteración 2, en la normalización iterativa, son realizados sobre los pixeles que no detectaron cambios.




FIGURA 4.8: Mascaras de cambio, iteración de la normalización radiométrica.

4.2.1.2. Discriminación Forestal

Las imágenes procesadas son aquellas obtenidas en la ultima normalización radiométrica, generada por el proceso iterativo y la imagen base para la semejanza en ese proceso. En este procedimiento se busca generar una mascara de vegetación (MV) de la secuencia temporal.

4.2.1.2.1. NDVI

El NDVI es calculado para ambas fechas pertenecientes a la secuencia multitemporal

evaluada ($ndvi_{f_t}, ndvi_{f_t*}$). El calculo es hecho teniendo como entradas las bandas infrarroja cercana y roja, donde el vigor vegetal de cada píxel sera determinado por la ecuación 3.2.

4.2.1.2.2. Umbral de Vegetación

El umbral que binariza la vegetación es determinado a partir de una constante calculada por un previo análisis del comportamiento espectral de la cobertura vegetal y las imágenes de NDVI, retornando una imagen binarizada $ndvi_{f_t}^B$ dado un $ndvi_{f_t}$. Dicha variable corresponde a la desviación observada (σ_c) en la intersección de puntos de muestreo aleatorios entre imágenes VCF y Landsat (sección 5.3.1). La ecuación que determina a $ndvi_{f_t}^B$ tiene la siguiente expresión:

$$ndvi_{f_t}^B(x, y) = \begin{cases} 1 & \text{si se cumple que } ndvi_{f_t}(x, y) > \mu_{ndvi_{f_t}} - n \times \sigma_c \\ 0 & \text{en cualquier otro caso} \end{cases} \quad (4.4)$$

Donde $\mu_{ndvi_{f_t}}$ representa la media de la imagen $ndvi_{f_t}$ y n el coeficiente de fiabilidad. En la Figura 4.9 podemos observar que el umbral del NDVI (línea roja) se situó por debajo de la media (línea fucsia) permitiéndonos discriminar los píxeles que representan vegetación/no vegetación.




FIGURA 4.9: Umbral utilizado y la media en el histograma de la imagen con NDVI.

4.2.1.2.3. Intersección área boscosa

El procedimiento que sigue una vez obtenido los NDVI de las dos fechas es determinar los pixeles que serán evaluados para detectar el cambio, por ello aplicamos una simple operación de unión ($ndvi_{f_t}^B$ OR $ndvi_{f_{t*}}^B$) que generara una mascara de vegetación MV correspondiente a los dos tiempos. La Figura 4.10 refleja los pasos realizados para obtener una mascara de vegetación.

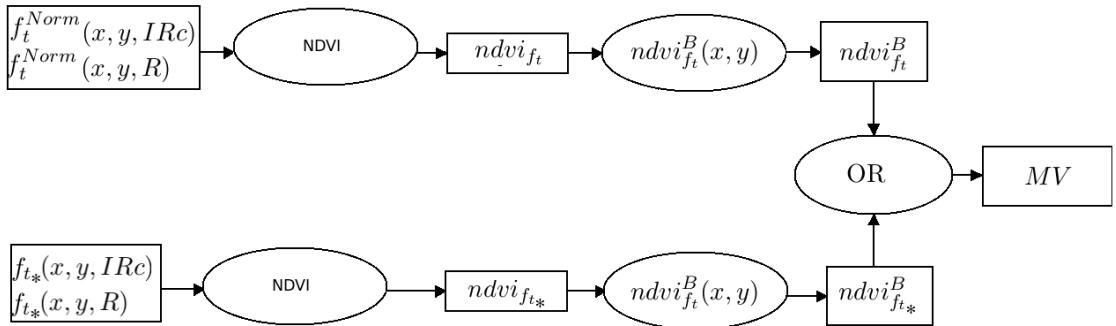


FIGURA 4.10: Diagrama de flujo. Discriminación Forestal.

4.2.1.3. Mascara de Pérdida Forestal

El proceso consiste en la intersección entre la mascaras de vegetación y cambio. En la intersección solo son considerados los cambios correspondiente a pérdidas MP , debido a que se pretende generar una imagen binaria MPF que represente la pérdida forestal en un pixel.

La imagen MPF probablemente tendrá errores que son inherentes a los procesos utilizados para su creación [LG01]. Estos errores lo consideramos como ruidos en la imagen MPF . El filtro de mediana [Gon02] reducirá el porcentaje de falsas alarmas en la imagen MPF eliminando los ruidos generados. En la Figura 4.11 podemos observar el flujo de tareas para la obtención de la mascara que representa la pérdida forestal en dos tiempos .

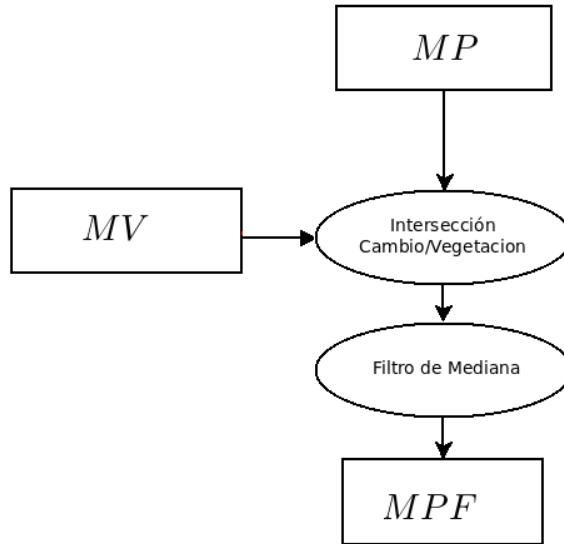


FIGURA 4.11: Diagrama de procedimientos para la obtención de la máscara de pérdida forestal.

4.2.2. Estimación de pérdida de carbono forestal

El procedimiento final en la metodología consiste en estimar el carbono perdido o no secuestrados dentro del tiempo transcurrido entre las imágenes satelitales. El producto constituye la máscara de pérdida forestal (*MPF*) junto con la cuantificación (*CCP*) en toneladas de carbono obtenida a través de una ecuación de regresión lineal. La ecuación de regresión fue generada por medio del mapa global de carbono (variable dependiente) [SHB⁺¹¹] y el NDVI (variable independiente) determinadas por las imágenes Landsat en un análisis previo (más detalles en la sección 5.3.2). La regresión fue evaluada a través del coeficiente de determinación r^2 . En la Tabla 4.3 se presenta el tipo de relación del coeficiente de determinación [Dur14b].

Valor	Significado
0,0	Ninguna Relación
0,25	Relación baja
0,50	Relación Moderada
0,75	Relación Buena
1,00	Relación perfecta

TABLA 4.3: Rangos del coeficiente de determinación.

Sea $C : (x, y) \rightarrow \{[-\infty, \infty]\}$ la cantidad de carbono, en toneladas por hectárea, para la coordenada (x, y) , se tiene que:

$$C(x, y) = h + m \times ndvi_f(x, y) \quad (4.5)$$

Donde $ndvi_f$ representa la variable independiente, C la variable dependiente y (h, m) coeficientes de la ecuación de regresión lineal.

La estimación de carbono para una secuencia multitemporal (C_t, C_{t_*}) en función al ndvi $(ndvi_t, ndvi_{t_*})$ queda definida de la siguiente manera:

$$C_t(x, y) = h + m \times ndvi_{f_t}(x, y) \quad (4.6)$$

$$C_{t_*}(x, y) = h + m \times ndvi_{f_{t_*}}(x, y) \quad (4.7)$$

El índice de cambio generado en la detección de cambio simplificaría los cálculos a la hora de estimar la pérdida, ya que:

$$Ic(x, y) = ndvi_{f_t}(x, y) - ndvi_{f_{t_*}}(x, y) \quad (4.8)$$

Podríamos restar la ecuación 4.6 y 4.7:

$$C_t(x, y) - C_{t_*}(x, y) = m \times (ndvi_{f_t}(x, y) - ndvi_{f_{t_*}}(x, y)) \quad (4.9)$$

$$PC(x, y) = C_t(x, y) - C_{t_*}(x, y) \quad (4.10)$$

Siendo $PC(x, y)$ toneladas de carbono por hectárea perdidos en un pixel con coordenadas (x, y) . Reemplazando 4.8 y 4.10 en 4.9, la ecuación de regresión final quedaría:

$$PC(x, y) = m \times Ic(x, y) \quad (4.11)$$

La ecuación 4.11 debe ser multiplicada por un factor de 0,09, debido a que los pixeles del mapa global de carbono representan toneladas de carbono por hectárea [SHB⁺¹¹] y la superficie mínima representada por las imágenes Landsat (utilizadas para el cálculo

de NDVI) es de $900 \text{ m}^2 = 0,09 \text{ has.}$. La ecuación final quedaría:

$$PC(x, y) = 0,09 \times m \times Ic(x, y) \quad (4.12)$$

Siendo la cantidad de carbono perdido (en toneladas de C) representado por la siguiente expresión:

$$CCP = \sum_{c=0}^{fil} \sum_{d=0}^{col} PC(x, y) \quad (4.13)$$

La ecuación 4.13 será realizado teniendo en cuenta la máscara de pérdida forestal, es decir solo serán sumados aquellos pixeles que representa una pérdida según MPF. La Figura 4.12 nos muestra el resultado esperado por la metodología (MPF y CCP), donde los pixeles de color rojo representan pérdida de carbono forestal y los grises a pixeles en las cuales no hubo pérdida.




FIGURA 4.12: Presentación del resultado. Máscara de pérdida Forestal y la cantidad de carbono perdido.

4.2.3. Esquema general de la metodología

La metodología presenta un esquema general descripta por el Algoritmo 2, desde los datos de entrada hasta su finalización, de manera a brindar un resumen de los procesos realizados como también su aplicación en un ejemplo gráfico.

Algoritmo 2 Metodología para estimar pérdida de carbono

requiere: $f_t(x, y, IRc)$; $f_t(x, y, R)$, $f_{t*}(x, y, IRc)$; $f_{t*}(x, y, R)$

```

1:  $I_{c_{fil \times col}} = \begin{bmatrix} 0 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & 0 \end{bmatrix}$  // Indice de cambio  $I_c$ 
2:  $MC_{fil \times col} = \begin{bmatrix} 1 & \dots & 1 \\ \vdots & \ddots & \vdots \\ 1 & \dots & 1 \end{bmatrix}$  // Mascara de cambio  $MC$ 
3:  $seguir = verdadero$  // Variable que controla la iteración
4:  $\mu_{anterior} = 0$  // Media de  $I_c$  en la iteración anterior

5:  $iter = 0$ 
6: mientras  $seguir$  hacer
7:   // Se calculan las medias y desviaciones en función a una máscara si no es la
8:   // primera iteración (algoritmo 1)
9:    $[\mu_{R,t}, \mu_{IRc,t}, \sigma_{R,t}, \sigma_{IRc,t}] = \text{PARAMETROS}(f_t(x, y, R), f_t(x, y, IRc), MC)$ 
10:   $[\mu_{R,t*}, \mu_{IRc,t*}, \sigma_{R,t*}, \sigma_{IRc,t*}] = \text{PARAMETROS}(f_{t*}(x, y, R), f_{t*}(x, y, IRc), MC)$ 

11:  // Utilizar ecuación 3.18 para normalizar
12:   $f_{t*}^{Norm}(x, y, R) = \text{NORMALIZAR}(\mu_{R,t*}, \sigma_{R,t*}, \mu_{R,t}, \sigma_{R,t}, f_t(x, y, R), f_{t*}(x, y, R))$ 
13:   $f_{t*}^{Norm}(x, y, IRc) = \text{NORMALIZAR}(\mu_{IRc,t*}, \sigma_{IRc,t*}, \mu_{IRc,t}, \sigma_{IRc,t}, f_t(x, y, IRc), f_{t*}(x, y, IRc))$ 
14:  // Utilizar ecuación 3.2 para el cálculo de NDVI
15:   $ndvi_{f_t} = \text{calcNDVI}(f_t(x, y, R), f_t(x, y, IRc))$ 
16:   $ndvi_{f_{t*}} = \text{calcNDVI}(f_t^{Norm}(x, y, R), f_t^{Norm}(x, y, IRc))$ 

17:  // Calculamos  $I_c$ 
18:   $I_c = ndvi_{f_t} - ndvi_{f_{t*}}$ 
19:  // Utilizar ecuación 4.3
20:   $seguir = \text{continuar}(\mu_{anterior}, \text{MEDIA}(I_c))$ 
21:   $\mu_{anterior} = \text{MEDIA}(I_c)$ 

22:  // Calculamos  $MC$  según ecuación 4.1
23:   $MC = \text{UMBRALIZAR}(I_c)$ 

24:   $iter ++$ 
25: fin mientras

26: // Se determina la máscara de vegetación según la sección 4.2.1.2
27:  $MV = \text{MASCARA VEGETACION}(f_{t*}^{Norm}(x, y, R), f_{t*}^{Norm}(x, y, IRc), f_t(x, y, R), f_t(x, y, IRc))$ 
28:
29: // Se determina la máscara de pérdida según la ecuación 4.2
30:  $MP = \text{MASCARA PERDIDA}(I_c)$ 

31: // Se determina la máscara de pérdida forestal intersectando  $MC$  con  $MV$ 
32:  $MPF = MP \text{ AND } MV$ 

33: // Se estima la cantidad de carbono perdido mediante ecuación 4.13
34:  $CCP = \text{sumatoria}(MPF, I_c)$ 
retornar  $[CCP, MPF]$ 

```

Dada una secuencia multitemporal (f_t, f_{t*}) , donde $t < t_*$, con las bandas infrarroja cercana y roja de entrada ($f_t(x, y, IRC)$, $f_t(x, y, R)$, $f_{t*}(x, y, IRC)$, $f_{t*}(x, y, R)$) de una pequeña porción de cada imagen satelital, según la Figura 4.13, se realiza un ejemplo con una porción de 5×5 para f_t y f_{t*} :

$f_t(x, y, IRC)$	$f_{t*}(x, y, IRC)$
51 98 164 164 245	52 100 98 98 240
51 98 164 164 245	52 100 98 98 240
98 98 164 221 245	100 100 98 226 240
98 164 164 221 221	100 98 98 226 226
164 164 164 221 221	98 98 98 226 226

$f_t(x, y, R)$	$f_{t*}(x, y, R)$
40 200 19 19 102	41 202 5 5 111
40 200 19 19 102	41 202 5 5 111
200 200 19 34 102	202 202 5 28 111
200 19 19 34 34	202 5 5 28 28
19 19 19 34 34	5 5 5 28 28

FIGURA 4.13: Bandas de imágenes satelitales utilizados como entrada.

El proceso de iteración empieza normalizando radiométricamente las bandas de f_{t*} de manera a buscar la semejanza con las bandas de f_t . La normalización es realizado mediante la ecuación 3.18 habiendo calculado los parámetros estadísticos (Algoritmo 1) en base a una mascara de cambio MC , donde inicialmente sus niveles digitales valen 1. La Figura 4.14 nos muestra todos los procedimientos realizados en la primera iteración.

$f_t(x, y, IRC)$	$f_{t*}(x, y, IRC)$	$f_{t*}^{Norm}(x, y, IRC)$	$iter = 0$
51 98 164 164 245	52 100 98 98 240	88 130 128 128 253	
51 98 164 164 245	52 100 98 98 240	88 130 128 128 253	
98 98 164 221 245	100 100 98 226 240	130 130 128 241 253	
98 164 164 221 221	100 98 98 226 226	130 128 128 241 241	
164 164 164 221 221	98 98 98 226 226	128 128 128 241 241	

$\mu_{IRC,t} = 163$	$\mu_{IRC,t*} = 137$	$\mu_{IRC,t} + \frac{\sigma_{IRC,t}}{\sigma_{IRC,t*}} \cdot (f_{t*}(x, y, IRC) - \mu_{IRC,t*})$
$\sigma_{IRC,t} = 58.9$	$\sigma_{IRC,t*} = 67.1$	

$f_t(x, y, R)$	$f_{t*}(x, y, R)$	$f_{t*}^{Norm}(x, y, R)$
40 200 19 19 102	41 202 5 5 111	48 196 15 15 112
40 200 19 19 102	41 202 5 5 111	48 196 15 15 112
200 200 19 34 102	202 202 5 28 111	196 196 15 36 112
200 19 19 34 34	202 5 5 28 28	196 15 15 36 36
19 19 19 34 34	5 5 5 28 28	15 15 15 36 36

$\mu_{R,t} = 69.8$	$\mu_{R,t*} = 64.6$	$\mu_{R,t} + \frac{\sigma_{R,t}}{\sigma_{R,t*}} \cdot (f_{t*}(x, y, R) - \mu_{R,t*})$
$\sigma_{R,t} = 71.3$	$\sigma_{R,t*} = 77.5$	

$ndvi_{f_t}$	$ndvi_{f_{t*}}$	$I_c = ndvi_{f_t} - ndvi_{f_{t*}}$
0.121 -0.342 0.792 0.792 0.412	0.292 -0.203 0.790 0.790 0.384	-0.172 -0.140 0.002 0.002 0.028
0.121 -0.342 0.792 0.792 0.412	0.292 -0.203 0.790 0.790 0.384	-0.172 -0.140 0.002 0.002 0.028
-0.342 -0.342 0.792 0.733 0.412	-0.203 -0.203 0.790 0.739 0.384	-0.140 -0.140 0.002 -0.005 0.028
-0.342 0.792 0.792 0.733 0.733	-0.203 0.790 0.790 0.739 0.739	-0.140 0.002 0.002 -0.005 -0.005
0.792 0.792 0.792 0.733 0.733	0.790 0.790 0.790 0.739 0.739	0.002 0.002 0.002 -0.005 -0.005

MC	$\mu_{I_c} = -0.038$	$\sigma_{I_c} = 0.0713$
$\begin{matrix} 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 & 1 \\ 0 & 0 & 1 & 1 & 1 \\ 0 & 1 & 1 & 1 & 1 \\ 1 & 1 & 1 & 1 & 1 \end{matrix}$		
	$\mu_{anterior} = -0.038$	

$-0.11 = \mu_{I_c} - n \times \sigma_{I_c} < I_c(x, y) < \mu_{I_c} + n \times \sigma_{I_c} = 0.0328$	$iter + +$
--	------------

FIGURA 4.14: Primera iteración en el proceso de detección de cambio.

En la segunda iteración la mascara de cambio MC es tenido en cuenta para realizar el cálculo de los parámetros estadísticos solo sobre los píxeles que no sufrieron cambio ($MC(x, y) = 1$). La Figura 4.15 nos muestra la segunda iteración,

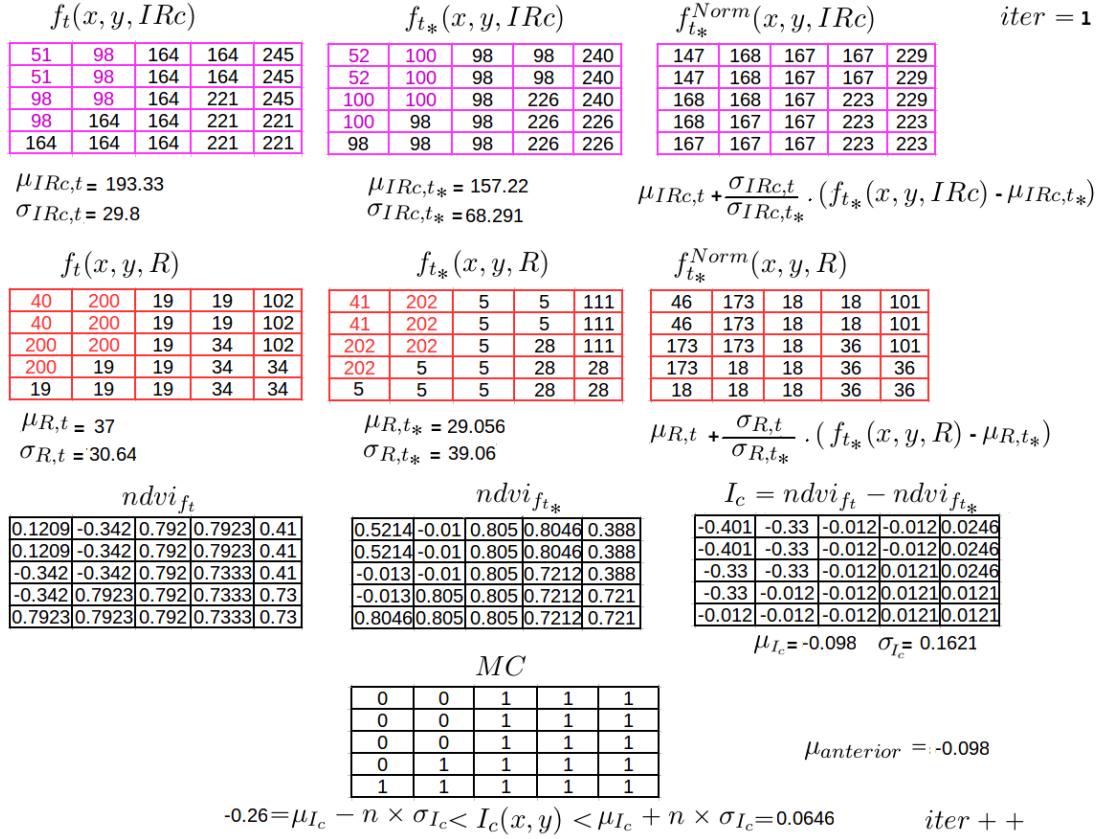


FIGURA 4.15: Segunda iteración en el proceso de detección de cambio.

En la Figura 4.16 podemos observar la siguiente iteración, donde la diferencia entre la media anterior $\mu_{anterior}$ y la media de I_c actual (μ_{I_c}) cumple con la ecuación 4.3 para un $\epsilon = 0$, finalizando así la iteración en la detección de cambio.

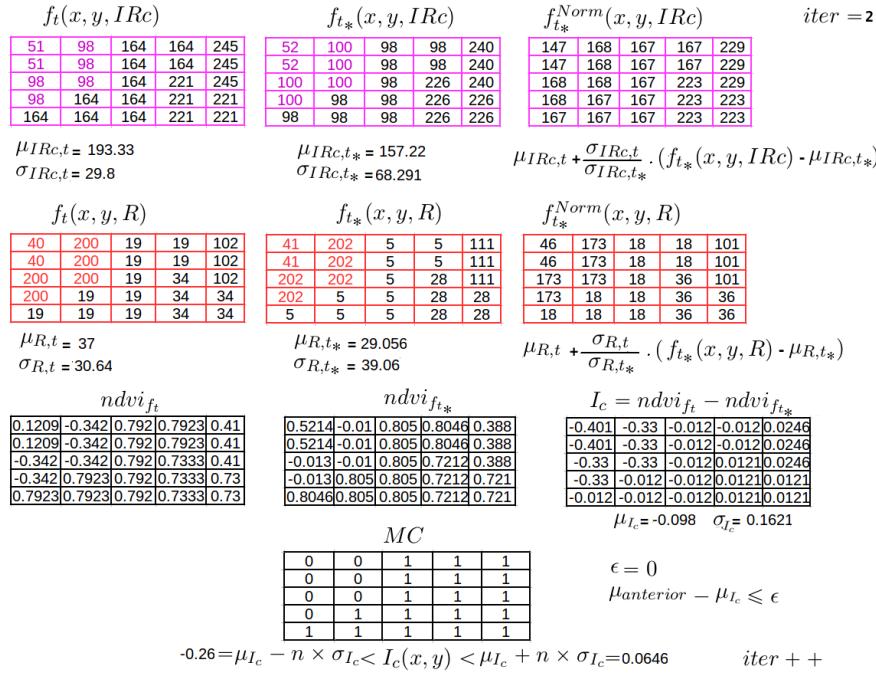



FIGURA 4.16: Última iteración en el proceso de detección de cambio.

La Figura 4.17 nos muestra como es obtenida la máscara de vegetación MV en función a $ndvi_{f_t}$ y $ndvi_{f_{t*}}$.

FIGURA 4.17: Determinación de la máscara de vegetación MV .

La Figura 4.18 podemos observar la forma en que es calculado la máscara de pérdida forestal y su cuantificación. En la figura se resalta en un cuadro rojo el resultado esperado por la metodología.

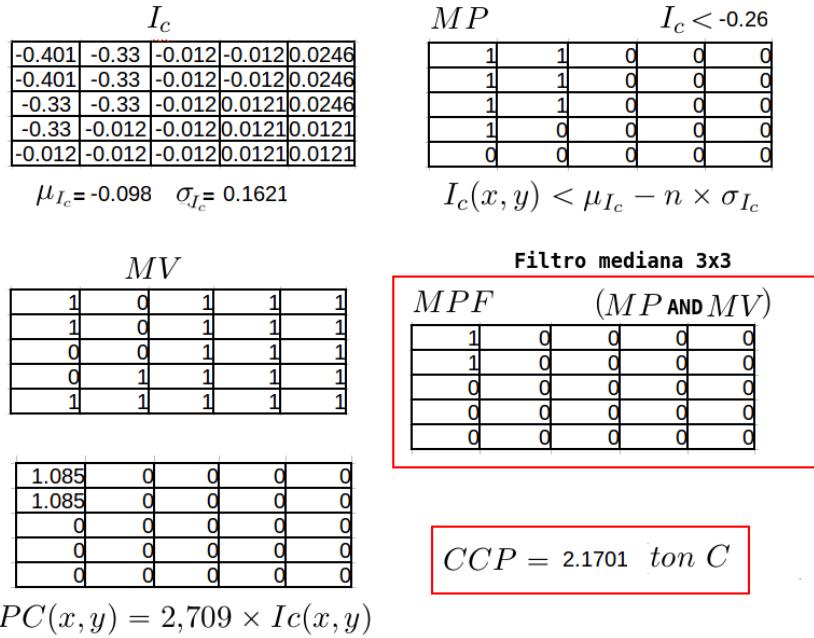


FIGURA 4.18: Máscara de cambio forestal y cuantificación de pérdida de carbono forestal.

4.3. Resumen

En este capítulo se describen los materiales y los tres procedimientos generales que componen la metodología propuesta. La imágenes infrarroja cercana y roja de las dos fechas inicialmente deben pasar por un proceso de corrección de errores del sensor y de ubicación geográfica para realizar el análisis multitemporal en la detección de cambio forestal. Una vez detectado la pérdida forestal entre las fechas del proceso de detección de cambio, se realiza la estimación de carbono en base a una ecuación de regresión hallado por un estudio previo. El resultado consiste en un mapa de pérdida forestal junto a la cuantificación en toneladas de carbono perdidos.

Capítulo 5

Pruebas experimentales

En este capítulo se menciona las métricas de evaluación utilizadas para medir el desempeño en la metodología propuesta. Los experimentos son detallados, junto a la comparación y la discusión de los mismos.

5.1. Caso de estudio

Filadelfia es una ciudad de Paraguay, del departamento de Boquerón - Chaco paraguayo (latitud-longitud $22^{\circ}20'00''S - 60^{\circ}01'00''O$) con una superficie de $13.879\ km^2$. La ciudad fue elevada a nivel de distrito en 2006. Su población la constituyen principalmente colonos menonitas. Fundada junto a otras localidades menonitas a finales de la década de 1920, ha desarrollado una cultura específica transmitida a lo largo de los siglos a través de la religión, y una infraestructura productiva que le aporta a sus residentes alto poder de compra. Estas comunidades menonitas trabajan con modernas técnicas de producción agropecuaria, fabricación de productos lácteos y procesamiento de sésamo y maní. Pueden ser ubicadas dentro de las imágenes landsat con path-Row 228-76 y en las VCF con código KJ1920.

La localización descripta fue elegida debido a que ademas de estar ubicada en el Chaco Paraguayo posee un crecimiento demográfico en la que las actividades agrícolas y ganaderas son variantes, proporcionando un ambiente ideal para las distintas pruebas y validaciones.

5.2. Métricas de evaluación

En el control de calidad, algunos se basan en el concepto de matriz de confusión, que establece una relación entre los resultados obtenidos en el proceso de asignación (Algoritmo) y la información verdad terreno (*VT*) disponible para la zona de estudio. En la Tabla 5.1, la diagonal principal representa el número de celdas correctamente catalogadas (*T*), y la diagonal transpuesta, las incorrectamente catalogadas (*F*). El uso de esta matriz presenta como mayor desventaja que está condicionada a la veracidad y exactitud de la referencia utilizada como *VT*. La interpretación de la matriz de confusión esta dada de la siguiente manera:

- TP: pixeles que se catalogaron como pérdida correctamente.
- FP: pixeles que se catalogaron como pérdida incorrectamente.
- P: total de pixeles catalogados como pérdida.
- FN: pixeles que se catalogaron como no pérdida incorrectamente.
- TN: pixeles que se catalogaron como no pérdida correctamente.
- N: total de pixeles catalogados como no pérdida.
- P': total de pixeles con pérdida.
- N': total de pixeles con no pérdida.

Categorías	Perdida (VT)	No Perdida (VT)	Total (VT)
Perdida (Algoritmo)	TP	FP	P
No Perdida (Algoritmo)	FN	TN	N
Total (Algoritmo)	P'	N'	Total

TABLA 5.1: Matriz de Confusión

Esta matriz de confusión, permite extraer distintos parámetros que evalúen la calidad del resultado obtenido en un proceso de detección de cambios utilizando técnicas de teledetección. A continuación se explican los dos parámetros más utilizados para este propósito: el porcentaje de precisión global y el coeficiente Kappa. Estas medidas de

la precisión se han utilizado para evaluar diferentes métodos de detección de cambio [Foo02].

5.2.1. Porcentaje de precisión global

El porcentaje de precisión global (Global Acurrancy, GA) se define como la suma del número de píxeles clasificadas correctamente dividido por el número total de píxeles que componen el área de referencia, representando la verdad terreno. Los resultados a partir de un 85 % de precisión global son considerados óptimos [Foo02]. La expresión matemática de la precisión global es:

$$GA = \frac{TP + TN}{T + F} \cdot 100 \quad (5.1)$$

5.2.2. Coeficiente Kappa

El coeficiente Kappa es otro indicador utilizado frecuentemente en un proceso de tele-detección para realizar el control de calidad de los resultados [Chu98]. Este coeficiente es una medida de la correspondencia entre los resultados de la detección de cambios y los datos verdad-terreno tomados como referencia, en otras palabras es una medida estadística que ajusta el efecto del azar en la proporción de la concordancia observada para elementos cualitativos (variables categóricas).

El coeficiente Kappa esta definida con la siguiente expresión:

$$KAPPA = \frac{Total \times (TP + TN) - (P \times P' + N \times N')}{Total^2 \times (P \times P' + N \times N')} \quad (5.2)$$

La Tabla 5.2 nos presenta la interpretación del coeficiente Kappa [LK77].

Coeficiente Kappa	Fuerza de la concordancia
0,00	Pobre
0,01-0,20	Leve
0,21-0,40	Aceptable
0,41-0,60	Moderada
0,61-80	Considerable
0,81-1,00	Casi perfecta

TABLA 5.2: Valoración del coeficiente kappa.

5.3. Pruebas y resultados experimentales

En esta sección se describirán las diferentes pruebas desarrolladas para la determinación de constantes establecidas dentro de la metodología. Los resultados obtenidos por la metodología son expuestos de manera a evaluar los datos de salida mediante las métricas planteadas.

5.3.1. Umbral de Vegetación

En la metodología hemos hablado y utilizado una variable estadística (sección 4.2.1.2.2) hallada por un análisis previo del comportamiento espectral que presenta la cobertura vegetal. Dicha variable corresponde a la desviación estandar de los NDVI encontrados.

Las imágenes VCF (sección 4.1.1.2) junto con las imágenes Landsat (sección 4.1.1.1) permitieron realizar un pareo de niveles digitales en base a su posición geográfica (x, y). En las imágenes VCF los píxeles representan porcentajes de vegetación existente en un pixel, mientras que las imágenes Landsat nos permite calcular NDVI. Imágenes con NDVI fueron calculadas para diferentes tiempos (1986, 1990, 2000). Existe una colección disponible de imágenes VCF, del año 2000 hasta el 2010, en la que se tomó el año 2000 como referencia por observar mayor porcentaje de cobertura vegetal que las demás para ser cruzada con las imágenes de NDVI. Mascaras de VCF fueron elaboradas en diferentes rangos (0 %-10 %, 0 %-20 %, 0 %-30 %, 0 %-40 y 0 %-50). El rango completo no fue analizado debido a que no existen píxeles que representan la vegetación en un porcentaje

mayor al 50 %. En la Figura 5.1 podemos observar la mascara de VCF para píxeles con 30 % de vegetación junto con la imagen NDVI correspondiente al año 2000.

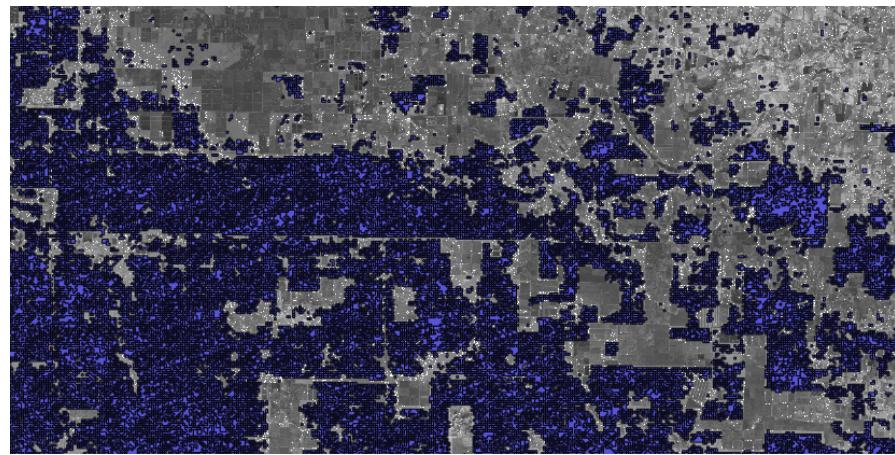


FIGURA 5.1: Mascara VCF de 0-30 % sobre NDVI año 2000

En la Figura 5.2 podemos observar parte de los 2000 puntos aleatorios extraídos de la mascara VCF (0 %-30 %) para ser cruzados con los niveles digitales de las imágenes NDVI.

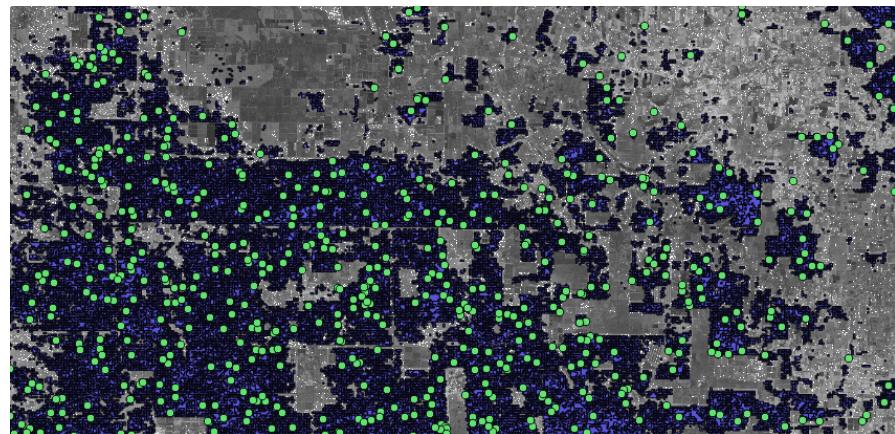


FIGURA 5.2: Puntos aleatorios dentro de la mascara VCF.

El procedimiento se repite para cada mascara en los distintos rangos. En total se obtiene 5 grupos por cada año estudiado con estadísticas ilustrada en la Tabla 5.3.

Año 1986		
VCF (%)	$\mu_{ndvi_{ft}}$	$\sigma_{ndvi_{ft}}$
50	0.356701	0.047891
40	0.344022	0.0507296
30	0.337696	0.061581
20	0.339586	0.0632055
10	0.335528	0.0727573
Año 1990		
VCF (%)	$\mu_{ndvi_{ft}}$	$\sigma_{ndvi_{ft}}$
50	0.278804	0.0631834
40	0.264651	0.0679451
30	0.254145	0.0742348
20	0.252186	0.0759032
10	0.251421	0.0796667
Año 1990		
VCF (%)	$\mu_{ndvi_{ft}}$	$\sigma_{ndvi_{ft}}$
50	0.0202133	0.0572825
40	0.0104289	0.0608757
30	-0.00337075	0.066776
20	-0.00663188	0.0695777
10	-0.0103891	0.0757546

TABLA 5.3: Media y desviación del muestreo realizado.

La Tabla 5.3 nos muestra que la media del NDVI es diferente para cada año, independientemente del porcentaje de vegetación evaluado, debido a que el área foliar (hojas) en la vegetación posee diferente respuestapectral para cada especie y época en la que es capturada por los sensores remotos. En este caso, no es conveniente tomar la media ($\mu_{ndvi_{ft}}$) dentro de un patrón de comportamiento con el fin de discriminar la vegetación. Las desviaciones ($\sigma_{ndvi_{ft}}$) se observan próximas para cada evaluación por lo que consideramos resaltante y útil para la discriminación forestal. Un promedio entre todas las desviaciones es realizado quedando como variable σ_c en la umbralización de vegetación $\sigma_c = 0,0658242733$.


5.3.2. Estimación de pérdida de carbono forestal

El Mapa Global de Carbono nos permite analizar una relación posible con los índices de vegetación. Los NDVI fueron calculados a partir de imágenes Landsat del año 2003, debido a que el Mapa Global de Carbono corresponde a la década del año 2000 (como se había comentado en la sección 4.1.1.3). Posteriormente se generaron 240 puntos aleatorios dentro áreas que correspondían a vegetación como podemos observar en la Figura 5.3.



FIGURA 5.3: Puntos aleatorios.

Estos puntos fueron generados para interceptar en ellos los NDVI y ton C/ha en el espacio geográfico. De esa manera nos permitió realizar un análisis de regresión lineal, como podemos ver en la Figura 5.4, donde el coeficiente de determinación fue moderado ($r^2 = 0,509125$), .

FIGURA 5.4: Regresión Lineal. $X = NDVI$, $Y = TonC/ha$

Los coeficientes de la ecuación 4.5 encontrados en el experimento corresponden a $m = 30,1$ y $h = 4,33$, quedando la ecuación con la siguiente expresión:

$$C(x, y) = 4,33 + 30,1 \times ndvi_f(x, y) \quad (5.3)$$

La ecuación 4.12 determinada en base a la imagen de índice de cambio I_c queda con la siguiente expresión una vez remplazado el coeficiente m :

$$PC(x, y) = 2,709 \times Ic(x, y) \quad (5.4)$$

5.3.3. Prueba experimental

Con el propósito de evaluar la calidad en la detección de cambio, se obtuvieron las imágenes que fueron utilizadas en la elaboración del Paraguay Forest Change Product (sección 4.1.1.4). Dichas imágenes corresponden a la fecha 1-26-1992 del satélite Landsat-5 y 8-17-1999 del satélite Landsat-7, con path-row 228-76 del WRS-2 cubriendo al área del caso de estudio.

Sectores fueron delimitados en base al uso del suelo empleado en dicha área. Esto es con el fin de evaluar la detección en diferentes condiciones:

- **Área Urbana:** zona de aglomeramiento y mayor densidad poblacional. Existe predominio de actividades económicas no agropecuarias, sumado a la población total.
- **Área Rural:** se caracteriza por la inmensidad de espacios verdes que la componen y que por esta razón está destinada y es utilizada para la realización de actividades agropecuarias y agro-industriales.
- **Área Húmeda:** zona de tierras, generalmente planas, cuya superficie se inunda de manera permanente o intermitente.

En la Figura 5.5 podemos observar las áreas seleccionadas dentro de la imagen satelital. El área urbana contiene a la zona céntrica del distrito de Filadelfia mientras que el área rural a zonas retiradas donde la vegetación es predominante. Las áreas húmedas corresponden a zonas cercanas al río Pilcomayo, donde las inundaciones a causa de subidas del río son frecuentes.

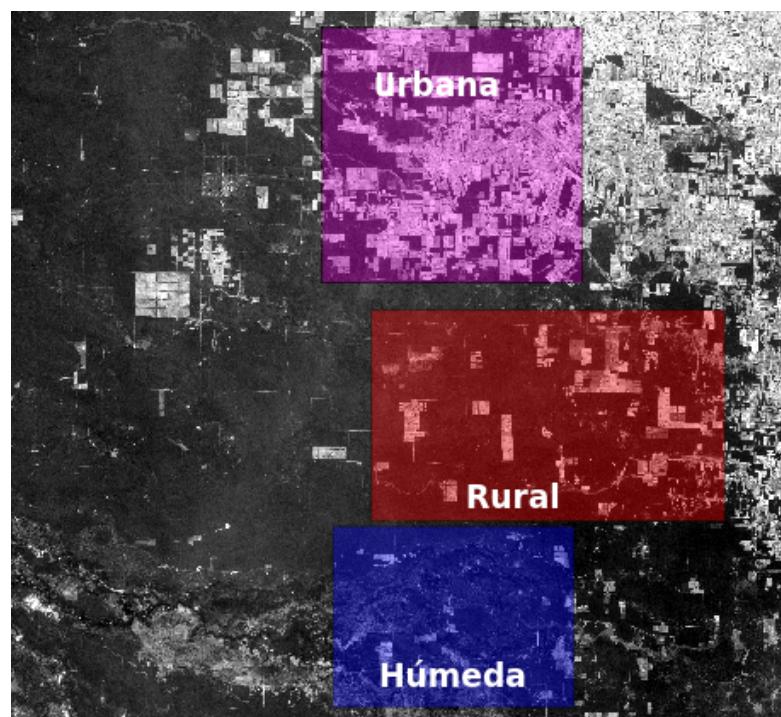


FIGURA 5.5: Áreas de los sectores empleados para los experimentos.

En la Tabla 5.4 podemos observar las coordenadas de los polígonos (xMax,yMax,xMin,yMin) con su perímetro (Km) y área (Has.) correspondiente a cada sector elegido.

Sector	xMin	yMin	xMax	yMax	Has.	Km.
Urbano	748797.48	-2532113.76	799869.96	-2482116.50	255348.41	202.13
Rural	758474.37	-2578885.40	827825.42	-2537489.81	287082.72	221.49
Húmedo	750947.90	-2615442.54	798257.14	-2579960.61	167862.32	165.58

TABLA 5.4: Polígono de las áreas. Sistema de coordenadas UTM Zona 20 K.

El proceso de corrección de las imágenes satelitales (sección 3.6), debido a que obtuvieron los productos L1T del USGS (sección 4.1.1.1), no fueron implementados por ya poseer el pre-procesamiento de corrección geométrica y radiométrica correspondiente. Esto es beneficioso al estudio en cuanto a costo, por no ser necesario el levantamiento de los puntos de control (GCP) en el terreno para la corrección geométrica específicamente.

El ϵ utilizado para el punto de parada en el proceso de iteración es de 0,01.

Las imágenes satelitales de entrada son de baja resolución espacial (30×30 metros cuadrados) por lo que el tamaño de ventana a utilizar sería 3×3 en el filtro de mediana.

La Tabla 5.5 nos muestra los path/row (sección 4.1.1.1) de las imágenes utilizadas en nuestro experimento.

Satélite	Path-row	Fecha
Landsat-5	228-76	1-26-199
Landsat-7	229-76	8-17-1999

TABLA 5.5: Path/row de las imágenes utilizadas en el experimento.

Se recortaron las bandas de las imágenes, infrarroja cercana y roja, para cada sector y fecha e introducidas como datos de entrada en la metodología. Las Figura 5.6 muestra la máscara de pérdida forestal (MPF) junto con la cuantificación de carbono (CCP) en el área urbana para cada coeficientes de fiabilidad (n) (sección 4.2.1.1.2), obtenidos luego de aplicar la metodología presentada.




FIGURA 5.6: Área Urbana. Mapa de pérdida forestal y toneladas de carbono perdidos.

La Figura 5.7 muestra la máscara de pérdida forestal (*MPF*) junto con la cuantificación de carbono (*CCP*) en el área rural para cada coeficientes de fiabilidad (*n*) (sección 4.2.1.1.2), obtenidos luego de aplicar la metodología presentada.




FIGURA 5.7: Área Rural. Mapa de pérdida forestal y toneladas de carbono perdidos

La Figura 5.8 muestra la máscara de pérdida forestal (*MPF*) junto con la cuantificación de carbono (*CCP*) en el área húmeda para cada coeficientes de fiabilidad (*n*) (sección 4.2.1.1.2), obtenidos luego de aplicar la metodología presentada.




FIGURA 5.8: Área Húmeda. Mapa de pérdida forestal y toneladas de carbono perdidos

La evaluación de la calidad en la detección de pérdida forestal (MP) fueron hechas con la comparación del Paraguay Forest Change Product (PFCP) y los resultados obtenidos por cada sector y coeficiente de tolerancia (n). El indice kappa y la precisión global nos permitía saber la calidad en los resultados de detección de cambio forestal.

Una re-clasificación en la imagen PFCP fue realizado previamente, ya que en ella clasifica dos tipos de bosques (Atlántico y Chaco), no bosques y agua. La re-clasificación consistió en dejar solo los pixeles que representan pérdida de vegetación en cualquier de los tipos, generando una imagen binaria (rojo para pixeles con pérdida forestal y amarillo otros) como podemos observar en la Figura 5.9.

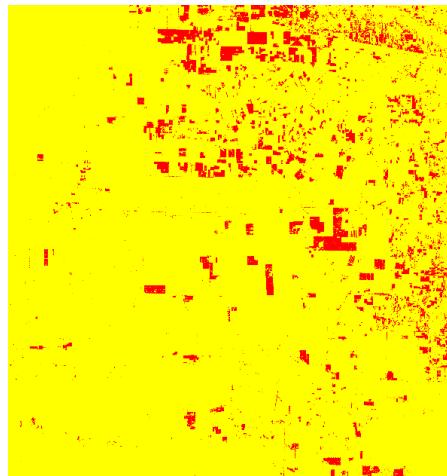


FIGURA 5.9: Re-clasificación de la imagen PFCP. Perdida = 1, Otros=0

Una vez generado la imagen de referencia para la evaluación con ayuda de la aplicación GRASS GIS se obtuvo los siguientes resultados:

N=1		
Área	Kappa	Precisión Global
Urbano	0.476389	84.257452
Rural	0.65782	93.82121
Húmeda	0.301541	90.624794
N=1.5		
Área	Kappa	Precisión Global
Urbano	0.315273	83.514875
Rural	0.671753	94.899171
Húmeda	0.425555	96.693648
N=2		
Área	Kappa	Precisión Global
Urbano	0.09368	81.642457
Rural	0.570687	94.33648
Húmeda	0.425555	96.693648

TABLA 5.6: Coeficiente Kappa y precisión Global obtenidos.

En la Figura 5.10 podemos observar que los coeficientes kappas en todos los n son mejores para zonas rurales, variando en resultados moderados y considerables. Las zonas

húmedas, donde $n = 1$ se obtienen resultados aceptables a diferencia de las demás que son moderadas. Por último las zonas urbanas son las que presentan gran variación entre los coeficientes hallados para el, debiendo implementar tolerancia baja ($n = 1$), al modelo de detección, para obtener resultados moderados. Los coeficientes son interpretados según la Tabla 5.2.

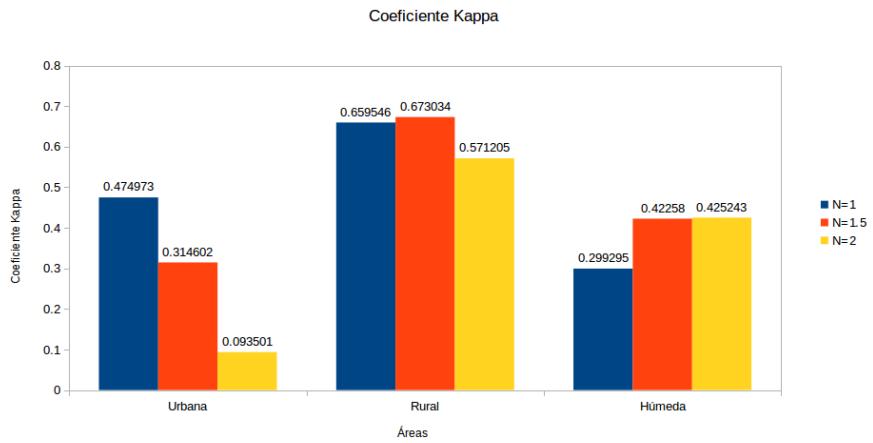


FIGURA 5.10: Coeficiente Kappa por cada Área y tolerancia.

La precisión global, según la ilustración 5.11, nos dice que el mejor resultado fue en la zona húmeda ($n = 2$) bajando el porcentaje para los demás tolerancias. Pero en zonas rurales obtenemos porcentajes parejos y elevados para cualquier n . Tanto para zonas húmedas y rurales según Jensen [Jen81] son óptimos por sobrepasar el 85 %. Las zonas urbanas se encuentran entre 81 % - 85 % próximos al umbral, lo que los deja sin ningún resultado satisfactorio.




FIGURA 5.11: GA por cada Área y tolerancia.

5.3.4. Dificultades encontradas

Unas de las principales dificultades encontradas fue de que las imágenes Landsat presentan un porcentaje de nubosidad en algunas fechas, por lo que requerirá de un preprocesamiento que permita su utilización en el análisis. Las correcciones geométricas constituyen un problema adicional si no se utilizan las imágenes Lansadt del USGS (sección 4.1.1.1), ya que necesitaran de un previo trabajo de campo para el relevamiento de puntos de control necesarios en la corrección.

Los resultados evaluados en base a los objetivos propuestos, en el siguiente y último capítulo se exponen las conclusiones de este trabajo y finalmente trabajos futuros que puedan dar continuidad a este trabajo final de grado.

5.3.5. Discusión de resultados

Una vez evaluado las diferentes zonas de nuestro caso de estudio, podemos darnos cuenta que la metodología propuesta posee una mejor respuesta, respecto a la calidad, en áreas rurales. Esto es debido a que el Coeficiente kappa o los indices de acuerdo varían entre 0.57-0.67 y su precisión global sobrepasan el umbral optimo de 85 %, para cada coeficiente de tolerancia n . Por lo que se considera satisfactorio la metodología propuesta, ya que la pérdida de carbono es un fenómeno frecuente en áreas con vegetación predominante.

Zonas donde la vegetación no predomina, esta metodología podría no resultar suficientemente conveniente. Las pruebas experimentales hechas en zonas urbanas, la precisión global y el coeficiente kappa no son óptimos por el cual se llega a esa interpretación.

En áreas cercanas a ríos o sujetas a inundación, se observaron resultados aceptables para estudios con tolerancias medias y altas en la detección de pérdida forestal. El monitoreo en estos tipos de zonas con la metodología propuesta podría ser aun de gran utilidad, ya que la presencia de agua en la vegetación modifica la respuesta espectral, dificultando su clasificación como cobertura vegetal.

Los análisis estadísticos empleados tanto para la determinación de umbrales vegetación/no vegetación como en el hallazgo de ecuaciones de transformación a carbono, nos

indica que empleando extracciones de indices vegetales y variables estadísticas es posible generar metodologías no complejas destinadas al monitorio ambiental. Esta sencillez nos libera de necesarias supervisiones y entrenamientos normalmente empleadas en telede-tección.

El mapa global de carbono [SHB⁺¹¹] constituyó un factor importante para la automatización, al permitir determinar una ecuación que transforme el indice vegetal a carbono. De no existir, hubiese sido necesario aplicar previos muestreos forestales en el terreno.

La corrección geométrica implica procesos que engloba visitas al terreno para levantamientos de puntos de control requeridas en las interpolaciones. Gracias a la utilización de imágenes Landsat L1T proveídas por la USGS, no fue necesario sumar ese costo a la metodología.

Capítulo 6

Conclusiones y trabajos futuros

En base a los resultados obtenidos en la estimación de pérdida de carbono en nuestra área de estudio, este capítulo nos presenta las conclusiones y recomendaciones para investigaciones futuras derivadas del trabajo:

6.1. Conclusiones

- La normalización radiométrica permite que los pixeles de una secuencia multitemporal sean semejantes. Los índices de cambios obtenidos de la comparación multitemporal posibilitan obtener variables cualitativas a partir de umbrales elaborados por parámetros estadísticos extraídos de la misma imagen de cambio I_c . La iteración permite automatizar la detección de cambio, ya que el proceso normaliza repetidamente las imágenes teniendo en cuenta solo los pixeles que no sufrieron cambio en el tiempo, optimizando y mejorando la comparación multitemporal.
- El análisis estadístico realizado a las imágenes satelitales VCF y Landsat posibilitaron determinar a la desviación estándar de los NDVI calculados, como una constante que permite transformar las variables cuantitativas (NDVI) a variables cualitativas (vegetación/no vegetación).
- El análisis de regresión permitió encontrar una relación entre un índice de vegetación (NDVI) y el carbono (Mapa global de carbono), por lo que convertir el índice generado por las imágenes satelitales se resume en una ecuación que no implicó muestreo en campo ni estudios adicionales.

- La detección de cambio forestal fue realizado mediante a la normalización radiométrica y comparación multitemporal de forma iterativa, donde el cambio forestal fue discriminado mediante el hallazgo de la desviación estándar de los NDVI.
- En la detección de cambio forestal los resultados obtenidos fueron comparados con la imagen PFCP, de manera a evaluar el proceso con métricas de precisión global y coeficiente kappa.

La idea al elegir como caso de estudio parte del chaco paraguayo, es la de actuar de impulsora en la generación de herramientas para el monitoreo ambiental, donde con el empleo de procesamientos digital de imágenes satelitales que conlleven técnicas computacionalmente sencillas y automáticas podamos identificar alertas referentes a pérdida en el contenido de carbono forestal. De manera que una vez detectado, a través de las estimaciones, se puedan generar políticas de acción o prevención contra los daños posibles al ambiente. El chaco paraguayo es una región muy afectada actualmente por la degradación y deforestación en los bosques, donde la falta de recursos y el costo elevado en el monitoreo dificulta las intervenciones a tiempo, constituyendo un caso ideal e impulsora para la aplicación de metodologías como la propuestas en esta investigación.

6.2. Trabajos futuros

La metodología presenta diferentes dificultades y evaluaciones desarrolladas en los experimentos, por lo que a continuación se mencionan trabajos futuros con el fin de mejorar o extender la propuesta:

- Se pretende que la metodología propuesta siga mejorando en términos de preprocesamiento de las imágenes satelitales, ante factores que influyan en el momento de captura de los datos hechas por sensores remotos como también en técnicas que permita mejora la detección de cambio forestal.
- Proponer técnicas que permitan detectar y eliminar nubosidad en las imágenes satelitales.
- Mejorar la precisión global y el coeficiente kappa para zonas urbanas.

- Diseñar mejores técnicas que clasifique cobertura vegetal mediante la extracción de indices en todas las bandas.
- Adaptar la metodología, de manera a que permita recibir imágenes satelitales con diferentes resoluciones radiométricas.

Bibliografía

- [A⁺08] Arild Angelsen et al. *Moving ahead with REDD: issues, options and implications.* Cifor, 2008.
- [ACRR13] Dolors Armenteras, Edersson Cabrera, Nelly Rodríguez, and Javier Retana. National and regional determinants of tropical deforestation in colombia. *Regional Environmental Change*, 13(6):1181–1193, 2013.
- [ÁJB⁺01] G Ávila, F Jiménez, J Beer, M Gómez, and M Ibrahim. Almacenamiento, fijación de carbono y valoración de servicios ambientales en sistemas agroforestales en costa rica. carbon storage and fixation, and evaluation of environmental services in agroforestry systems in costa rica. *Agroforestería en las Américas (CATIE)*, 8(30):32–35, 2001.
- [AKB⁺05] Gregory P Asner, David E Knapp, Eben N Broadbent, Paulo JC Oliveira, Michael Keller, and Jose N Silva. Selective logging in the brazilian amazon. *Science*, 310(5747):480–482, 2005.
- [Ali10] Dr. Abdulrahman K. Ali. Remote sensing. 1, 2010.
- [AMVMEB⁺03] Miguel Acosta Mireles, Alejandro Velázquez Martínez, Jorge D Etchevers Barra, J Jesús Vargas Hernández, Hugo Ramírez Maldonado, Fabián Islas Gutiérrez, and ; Instituto de Recursos Naturales Programa Forestal. Colegio de Postgraduados, Campus Montecillo. *Diseño y aplicación de un método para medir los almacenes de carbono en sistemas con vegetación forestal y agrícolas de ladera en México.* PhD thesis, Tesis Doctoral. Colegio de Postgraduados. Montecillo, México, 2003.

- [BdFM03] Isabel Basualdo, Isabel Gamarra de Fox, and Miguel Angel Morales. *Estrategia nacional y plan de acción para la conservación de la biodiversidad del Paraguay: ENPAB, Estrategia Nacional y Plan de Acción de Biodiversidad, 2004-2009.* Presidencia de la República, Secretaría del Ambiente, 2003.
- [BLMP06] Corey Baker, Rick Lawrence, Clifford Montagne, and Duncan Patten. Mapping wetlands and riparian areas using landsat etm+ imagery and decision-tree-based models. *Wetlands*, 26(2):465–474, 2006.
- [CAGR10] Matthew L Clark, T Mitchell Aide, H Ricardo Grau, and George Riner. A scalable approach to mapping annual land cover at 250 m using modis time series data: A case study in the dry chaco ecoregion of south america. *Remote Sensing of Environment*, 114(11):2816–2832, 2010.
- [cal] QUÉ ES EL CALENTAMIENTO GLOBAL. <http://ecopolitica.net/que-es-el-calentamiento-global/>. [Internet; descargado 11-noviembre-2015].
- [Cas03] Benito Bernardo Dzib Castillo. Manejo, secuestro de carbono e ingresos de tres especies forestales de sombra en cafetales de tres regiones contrastantes de costa rica. 2003.
- [cha] Teledetecciónl. <http://laotraopinion.net/tecnologia/teledeteccion/poder-de-resolucion-espectral/>. [Internet; descargado 11-noviembre-2015].
- [Chu98] E Chuvieco. El factor temporal en teledetección: evolución fenomológica y análisis de cambios. *Revista de teledetección*, 10:39–48, 1998.
- [cic] Ciclo del carbono, sabes en qué consiste. <http://www.guioteca.com/educacion-para-ninos/ciclo-del-carbono-sabes-en-que-consiste/>. [Internet; descargado 11-noviembre-2015].
- [com] Composición de colores en las imágenes digitales. http://concurso.cnice.mec.es/cnice2006/material121/unidad1/i_colreal.htm. [Internet; descargado 16-noviembre-2015].

- [cor] Correcciones radiométricas. http://coello.ujaen.es/Asignaturas/teledeteccion/tel/tel_tfc_archivos/Tema9.pdf. [Internet; descargado 11-noviembre-2015].
- [DN] TÉCNICAS DE MUESTREO PARA MANEJADORES DE RECURSOS NATURALES. El espectro electromagnético. *Blanca*, page 455.
- [Dua12] Gustavo Miguel Huespe Duarte. *Detección de cambios de la cobertura vegetal mediante indices de vegetación (NDVI), dentro y fuera de la Reserva de la biosfera del Chaco en el periodo 1985-2011*. Universidad Nacional de Asunción, 2012.
- [Dur14a] Kris Vanessa Alamado Duré. *Estimación de carbono almacenado en el Parque Nacional Defensores del Chaco según formación vegetal mediante imágenes satelitales, año 2014*. Universidad Nacional de Asunción, 2014.
- [Dur14b] Kris Vanessa Alamado Duré. *Estimación de carbono almacenado en el Parque Nacional Defensores del Chaco según formación vegetal mediante imágenes satelitales, año 2014*. Universidad Nacional de Asunción, 2014.
- [Dur14c] Kris Vanessa Almando Dure. *Estimación de carbono almacenado en el Parque Nacional Defensores del Chaco según formación vegetal mediante imágenes satelitales, año 2014*. Universidad Nacional de Asunción, 2014.
- [els] EL SISTEMA DE REFERENCIA MUNDIAL LANDSAT-2 (WRS-2). http://geoinfoven.blogspot.com/2015/01/el-sistema-de-referencia-mundial_16.html. [Internet; descargado 11-noviembre-2015].
- [ERdR04] J Estornell, LA Ruiz, and A del Rey. Análisis metodológico para la detección de cambios urbanos en la ciudad de valencia. *Revista de Teledetección*, 22:55–56, 2004.
- [Esp] Yusmary Espinoza. Secuestro de carbono en el suelo.

- [fao03] Revista internacional de silvicultura e industrias forestales. *Organización de las Naciones Unidas para la Agricultura y la Alimentación*, 54, 2003.
- [Foo02] Giles M Foody. Status of land cover classification accuracy assessment. *Remote sensing of environment*, 80(1):185–201, 2002.
- [GBNF07] Holly K Gibbs, Sandra Brown, John O Niles, and Jonathan A Foley. Monitoring and estimating tropical forest carbon stocks: making redd a reality. *Environmental Research Letters*, 2(4):045023, 2007.
- [gl215] Global Land Cover Facility. <http://glcf.umd.edu/>, 2015.
- [GMKM⁺87] Apolo Rolando Garcidueñas Martínez, R Keyes, Martínez Menez Michael, R Mario, Zarate Lara, P Guillermo, and ; Programa Forestal. Colegio de Postgraduados, Campus Montecillo. *Producción de biomasa y acumulación de nutrientes en un rodal de Pinus montezumae Lamb.* PhD thesis, Tesis de Maestría. Colegio de Postgraduados, Montecillos, México, 1987.
- [Gon02] RC—Woods Gonzalez. Re: Digital image processing. *Reading*, Addison Wesley, page 88, 2002.
- [GRG⁺13] Clovis Grinand, Féty Rakotomalala, Valéry Gond, Romuald Vaudry, Martial Bernoux, and Ghislain Vieilledent. Estimating deforestation in tropical humid and dry forests in madagascar from 2000 to 2010 using multi-date landsat satellite images and the random forests classifier. *Remote Sensing of Environment*, 139:68–80, 2013.
- [GS03] M Garzuglia and M Saket. Wood volume and woody biomass. *Food and Agricultural Organization of the United Nations. Roma*, page 30, 2003.
- [Gui99] ERDAS Field Guide. Erdas inc. *Atlanta, Georgia*, 672:94, 1999.
- [GW15] Yingxin Gu and Bruce K Wylie. Downscaling 250-m modis growing season ndvi based on multiple-date landsat images and data mining approaches. *Remote Sensing*, 7(4):3489–3506, 2015.

- [HBH⁺12] Nancy L Harris, Sandra Brown, Stephen C Hagen, Sassan S Saatchi, Silvia Petrova, William Salas, Matthew C Hansen, Peter V Potapov, and Alexander Lotsch. Baseline map of carbon emissions from deforestation in tropical regions. *Science*, 336(6088):1573–1576, 2012.
- [HKS⁺09] Chengquan Huang, Sunghee Kim, Kuan Song, John RG Townshend, Paul Davis, Alice Altstatt, Oscar Rodas, Alberto Yanosky, Rob Clay, Compton J Tucker, et al. Assessment of paraguay’s forest cover change using landsat observations. *Global and Planetary Change*, 67(1):1–12, 2009.
- [Jen81] John R Jensen. Urban change detection mapping using landsat digital data. *The American Cartographer*, 8(2):127–147, 1981.
- [lan13] Landsat Project Description. http://landsat.usgs.gov//about_project_descriptions.php, 2013. [Internet; descargado 28-octubre-2015].
- [LB05] Dengsheng Lu and Mateus Batistella. Exploring tm image texture and its relationships with biomass estimation in rondônia, brazilian amazon. *Acta Amazonica*, 35(2):249–257, 2005.
- [LG01] JL Lovell and RD Graetz. Filtering pathfinder avhrr land ndvi data for australia. *International Journal of Remote Sensing*, 22(13):2649–2654, 2001.
- [LK77] J Richard Landis and Gary G Koch. The measurement of observer agreement for categorical data. *biometrics*, pages 159–174, 1977.
- [LKC14] Thomas Lillesand, Ralph W Kiefer, and Jonathan Chipman. *Remote sensing and image interpretation*. John Wiley & Sons, 2014.
- [MD] Jaime Márquez Díaz. Estimación de carbono arboreo por medio de imágenes del satélite spot en la región de tlaxco, tlaxcala/por jaime márquez díaz. page 157.
- [MD05] J Martínez and A Díaz. Percepción remota: fundamentos de teledetección espacial. *Recuperado 12 de 11 de 2011, de http://sigar. cna. gob.*

- mx/SIGA/Percepcion/Fundamentos % 20de % 20teledetect i % C3 % B3n % 20espacial. PDF*, 2005.
- [MG13] Raul Martínez Garrido. Normalización radiométrica iterativa en detección de cambios: seguimiento del tipo de cambios asociados al ecosistema mediterráneo. 2013.
- [MR99] A Mateu and LA Ruiz. Comparación y evaluación de métodos de normalización radiométrica relativa. *Revista de Teledetección*, 12:99–103, 1999.
- [nat15] El ciclo del carbono. http://www.natureduca.com/cienc_gen_ciclocarbono.php, 2015.
- [ndv] NDVI COMO HERRAMIENTA ÚTIL EN LA EVOLUCIÓN DE ECOSISTEMAS. <http://constanzarojasg.blogspot.com/2014/06/ndvi-como-herramienta-util-en-la.html>. [Internet; descargado 11-noviembre-2015].
- [Nel] Corcoran E. Duarte C. M. Valdés L. De Young C. Fonseca L. Grimsditch G Nellemann, C. Carbono azul. evaluación de una respuesta rápida.
- [OAA⁺15] Jean Pierre Ometto, Ana Paula Aguiar, Talita Assis, Luciana Soler, Pedro Valle, Graciela Tejada, David M Lapola, and Patrick Meir. Amazon forest biomass density maps: tackling the uncertainty in carbon emission estimates. In *Uncertainties in Greenhouse Gas Inventories*, pages 95–110. Springer, 2015.
- [Oje13] Fabian Miguel Peralta Ojeda. *Análisis del cambio de cobertura de la tierra y estimación de carbono en el área para Parque Nacional San Rafael, año 2008/2013*. Universidad Nacional de Asunción, 2013.
- [osg15] osgeo. Grass-wiki, 2015. [Internet; descargado 28-octubre-2015].
- [Par] WWF Paraguay y la Facultad de Ciencias Agrarias ParLu. Desarrollo del estudio de lÍnea de base para el sitio piloto bosque atlantico alto parana (baapa).

- [Piz10] Cecilia Pizzurno. Proyecto de evaluación de flujos de inversión y financieros para la mitigación al cambio climático en paraguay. 54, 2010.
- [PO11] María Pérez Ortega. Aplicaciones de la teledetección y sig en la caracterización de humedales en la reserva de la biosfera de la mancha húmeda. 2011.
- [PSD⁺15] Michael W Palace, Franklin B Sullivan, Mark J Ducey, Robert N Treuhaft, Christina Herrick, Julia Z Shimbo, and Jonas Mota-E-Silva. Estimating forest structure in a tropical forest using field measurements, a synthetic model and discrete return lidar data. *Remote Sensing of Environment*, 161:1–11, 2015.
- [QGI15] QGIS. Un sistema de información geográfica libre y de código abierto, 2015. [Internet; descargado 28-octubre-2015].
- [RAAKR05] Richard J Radke, Srinivas Andra, Omar Al-Kofahi, and Badrinath Roy-sam. Image change detection algorithms: a systematic survey. *Image Processing, IEEE Transactions on*, 14(3):294–307, 2005.
- [RGGSCO⁺10] VF Rodríguez-Galiano, MJ García-Soldado, M Chica-Olmo, E Pardo Igúzquiza, JP Rigol-Sánchez, and M Chica-Rivas. Análisis de cambios de usos del suelo en la «vega de granada»: correcciones radiométricas y evaluación del cambio land-cover change analysis in «vega de granada»: radiometric corrections. *Revista de Teledetección*, 2010(34):5–15, 2010.
- [RMTB⁺15] Maxime Réjou-Méchain, Blaise Tymen, Lilian Blanc, Sophie Fauset, Ted R Feldpausch, Abel Monteagudo, Oliver L Phillips, Hélène Richard, and Jérôme Chave. Using repeated small-footprint lidar acquisitions to infer spatial and temporal variations of a high-biomass neotropical forest. *Remote Sensing of Environment*, 169:93–101, 2015.
- [Rob02] Michel Robert. *Captura de carbono en los suelos para un mejor manejo de la tierra*, volume 96. Food & Agriculture Org., 2002.
- [Sal02] Emilio Chuvieco Salinero. *Teledetección Ambiental: La observación de la Tierra desde el Espacio*. 2002.

- [SGG00] Bastienne Schlegel, Jorge Gayoso, and Javier Guerra. Manual de procedimientos para muestreos de biomasa forestal. *Universidad Austral de Chile*, 2000.
- [SH08] Zenia Salinas and Paulo Hernández. Guía para el diseño de proyectos mdl forestales y de bioenergía. 2008.
- [SHB⁺11] Sassan S Saatchi, Nancy L Harris, Sandra Brown, Michael Lefsky, Edward TA Mitchard, William Salas, Brian R Zutta, Wolfgang Buermann, Simon L Lewis, Stephen Hagen, et al. Benchmark map of forest carbon stocks in tropical regions across three continents. *Proceedings of the National Academy of Sciences*, 108(24):9899–9904, 2011.
- [SHS⁺14] Xiao-Peng Song, Chengquan Huang, Joseph O Sexton, Saurabh Chantran, and John R Townshend. Annual detection of forest cover loss using time series satellite measurements of percent tree cover. *Remote Sensing*, 6(9):8878–8903, 2014.
- [Sin89] Ashbindu Singh. Review article digital change detection techniques using remotely-sensed data. *International journal of remote sensing*, 10(6):989–1003, 1989.
- [SMIY00] SA Sader, EB Martinez, DE Irwin, and HT Yax. Estimación de la deforestación en la reserva de la biosfera maya, 1997-1999. *Nuevas Perspectivas de Desarrollo Sostenible en Petén. Ed. Guatemala, Guatemala, Facultad Latinoamericana de Ciencias Sociales (FLACSO)*, pages 321–324, 2000.
- [SRHS04] MVK Sivakumar, PS Roy, K Harmsen, and SK Saha. Satellite remote sensing and gis applications in agricultural meteorology. In *Proceedings of the Training Workshop in Dehradun, India. AGM-8, WMO/TD*, number 1182, 2004.
- [SZ05] FC Speranza and HR Zerda. Potencialidad de los índices de vegetación para la discriminación de coberturas forestales. *Proyecto Picto*, 12931, 2005.
- [TBH⁺15] A Tyukavina, A Baccini, MC Hansen, PV Potapov, SV Stehman, RA Houghton, AM Krylov, S Turubanova, and SJ Goetz. Aboveground

- carbon loss in natural and managed tropical forests from 2000 to 2012. *Environmental Research Letters*, 10(7):074002, 2015.
- [tela] Correciones a las imágenes de satélites. <http://www.um.es/geograf/sigmur/teledet/tema07.pdf>. [Internet; descargado 11-noviembre-2015].
- [telb] Elementos de percepción remota. <http://www.inegi.org.mx/geo/contenidos/imgpercepcion/imgsatelite/elementos.aspx>. [Internet; descargado 11-noviembre-2015].
- [tel15] COMBINACIONES DE COLORES. <http://www.teledet.com.uy/tutorial-imagenes-satelitales/combinaciones-colores.htm>, 2015.
- [TL88] F Tung and Ellsworth LeDrew. The determination of optimal threshold levels for change detection using various accuracy indexes. *Photogrammetric Engineering and Remote Sensing*, 54(10):1449–1454, 1988.
- [Tom90] C Dana Tomlin. *A map algebra*. Harvard Graduate School of Design, 1990.
- [Tro12] Denise Trevisan Troche. *Identificación de cultivos mediante Imágenes Satelitales*. Universidad Nacional de Asunción, 2012.
- [Tsu12] Satoshi Tsuyuki. *Sensoramiento y tipos de sensores selección de datos de satélite*. Reducing Emissions from Deforestation and forest Degradation and the Role of Conservation, Sustainable Management of Forests and Enhancement, 2012.
- [Vás11] Juan Olegario Monroy Vásquez. Minería de datos con conjuntos aproximados para clasificación de imágenes satelitales (data mining with rough sets for classification of satellite images). *Ventana Informática*, (25):141, 2011.
- [Wik15] Wikipedia. Ciclo del carbono — wikipedia, la enciclopedia libre, 2015. [Internet; descargado 28-octubre-2015].